

# 法律声明

---

□ 本课件包括：演示文稿，示例，代码，题库，视频和声音等，小象学院拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意，我们将保留一切通过法律手段追究违反者的权利。

□ 课程详情请咨询

■ 微信公众号：小象

■ 新浪微博：ChinaHadoop



# 神经序列模型 IV

---

主讲人： 史兴

07/14/2017

# 提纲

---

□ Seq2Seq Model

□ Beam Search

□ Attention

# Seq2Seq Model

---

□ 核心:

■ 
$$p(E|F) = p(e_1^N | f_1^M)$$
$$= \prod_{i=1}^N p(e_i | e_1^{i-1}, f_1^M)$$

□ F: input sequence/source sequence

□ E: output sequence/target sequence

# Seq2Seq Model

□ 自然语言处理很多都可以转化成seq2seq

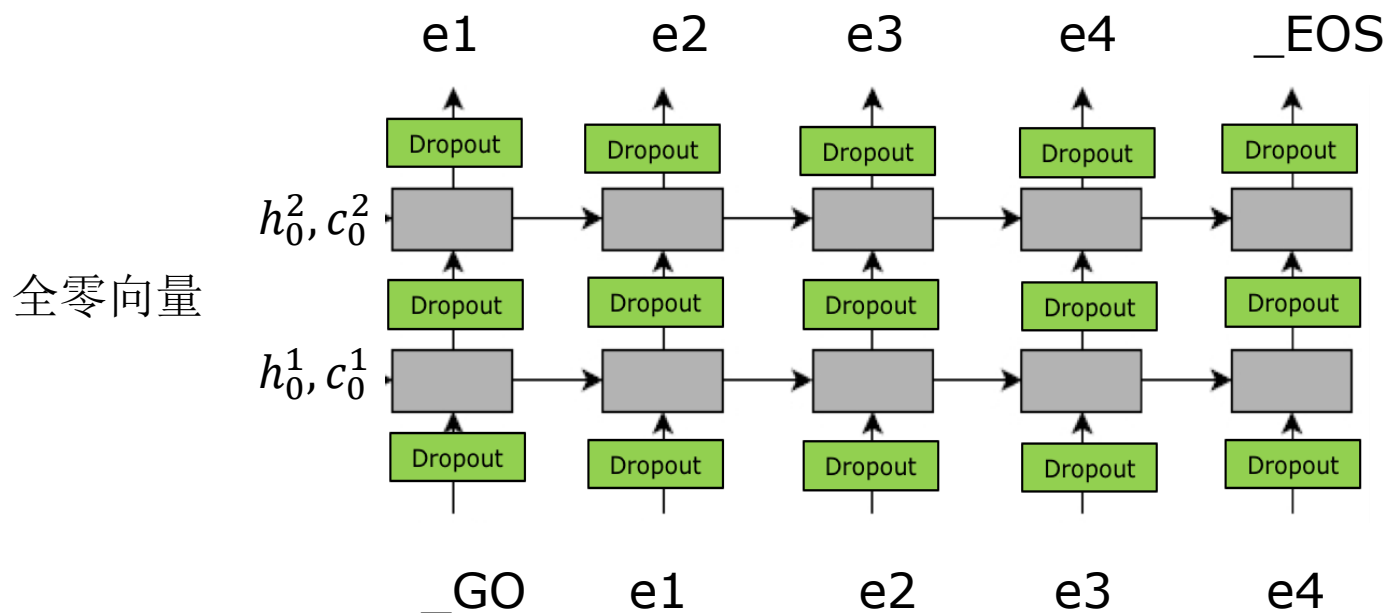
■ 核心:  $p(e_1^N | f_1^M) = \prod_{i=1}^N p(e_i | e_1^{i-1}, f_1^M)$

问题	E	F
语言模型	句子	null
机器翻译	中文	外文
句子分类	类别	句子
诗歌生成	诗句	主题词
对话机器人	回复	话语
问答系统	答案	问题

# Seq2Seq Model

## □ seq2seq 的结构

■ 核心:  $p(e_1^N | f_1^M) = \prod_{i=1}^N p(e_i | e_1^{i-1}, f_1^M)$



# Seq2Seq Model

## □ seq2seq 的结构

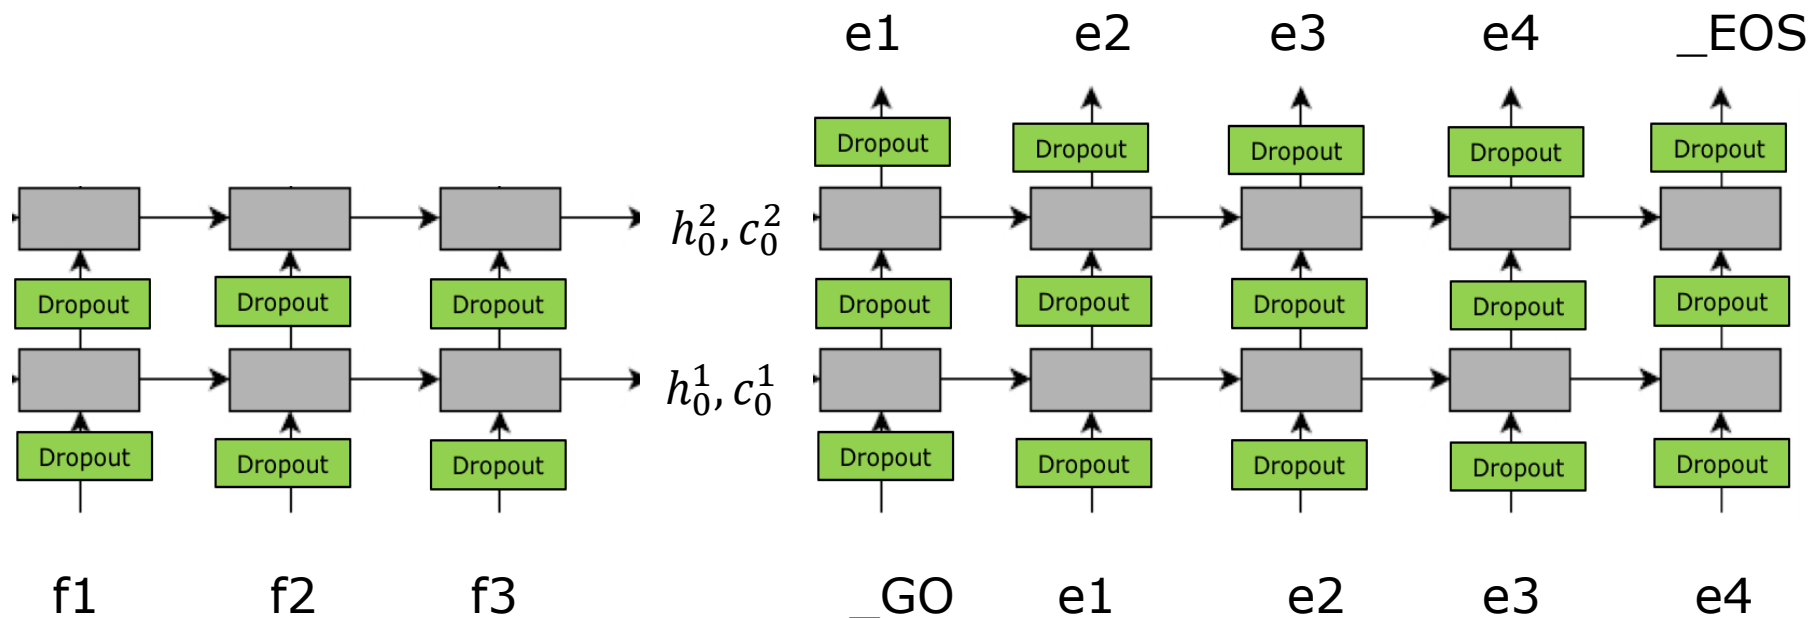
■ 核心:  $p(e_1^N | f_1^M) = \prod_{i=1}^N p(e_i | e_1^{i-1}, f_1^M)$

■  $h_0, c_0$  由另外一个LSTM来计算

Encoder

中间向量

Decoder



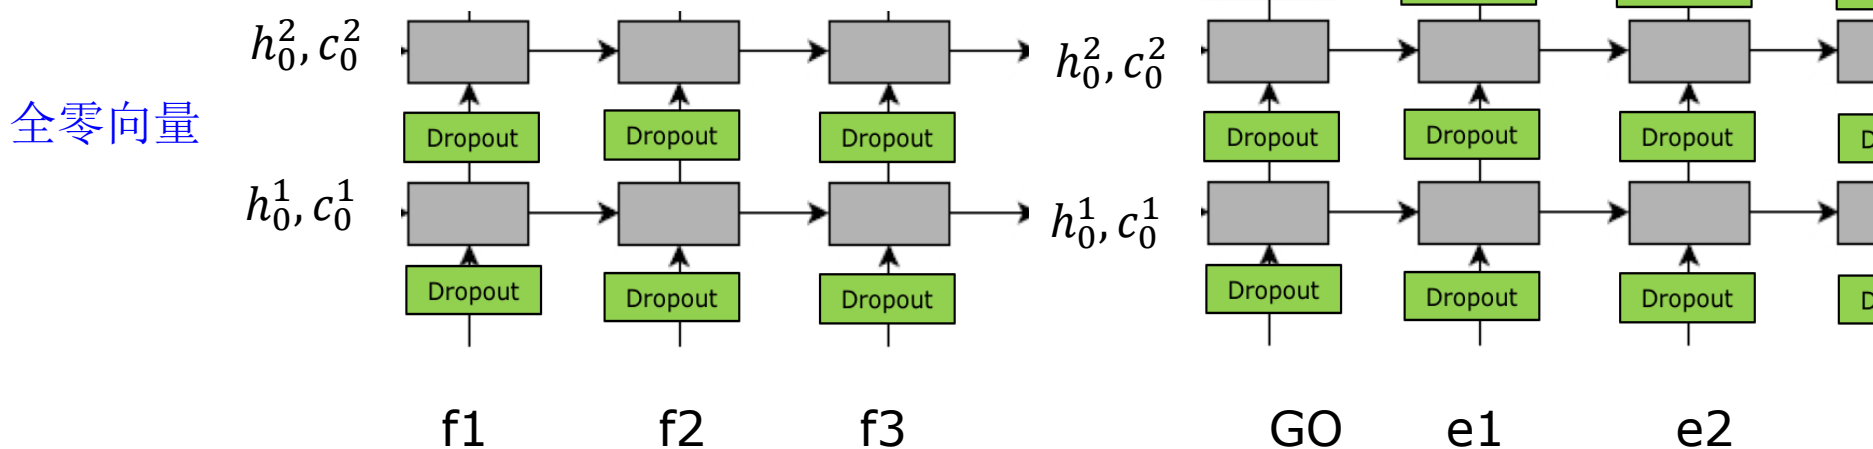
# Seq2Seq Model

□ 自然语言处理很多都可以转化成seq2seq

■ 核心:  $p(e_1^N | f_1^M) = \prod_{i=1}^N p(e_i | e_1^{i-1}, f_1^M)$

■ Encoder和Decoder是完全不同的参数

## Encoder的每一步并不预测任何东西





# Seq2Seq Model

## □ Seq2Seq的参数集合

### ■ 超参数

□ 层数= $n$ , hidden size= $d$

□ vocab for F =  $V_F$ , vocab for E =  $V_E$

### ■ Encoder:

□ Input: input embedding for f :  $|V_F| * d$

□ LSTM: 第一层, 第二层:  $n(8d^2 + 4d)$

### ■ Decoder:

□ Input: input embedding for e:  $|V_E| * d$

□ LSTM: 第一层, 第二层:  $n(8d^2 + 4d)$

□ Output:

■ output embedding for e:  $|V_E| * d$

■ output bias for e:  $|V_E|$

# Beam Search

---

## □ Language Model:

- 输入： 句子
- 输出：  $P(\text{句子})$

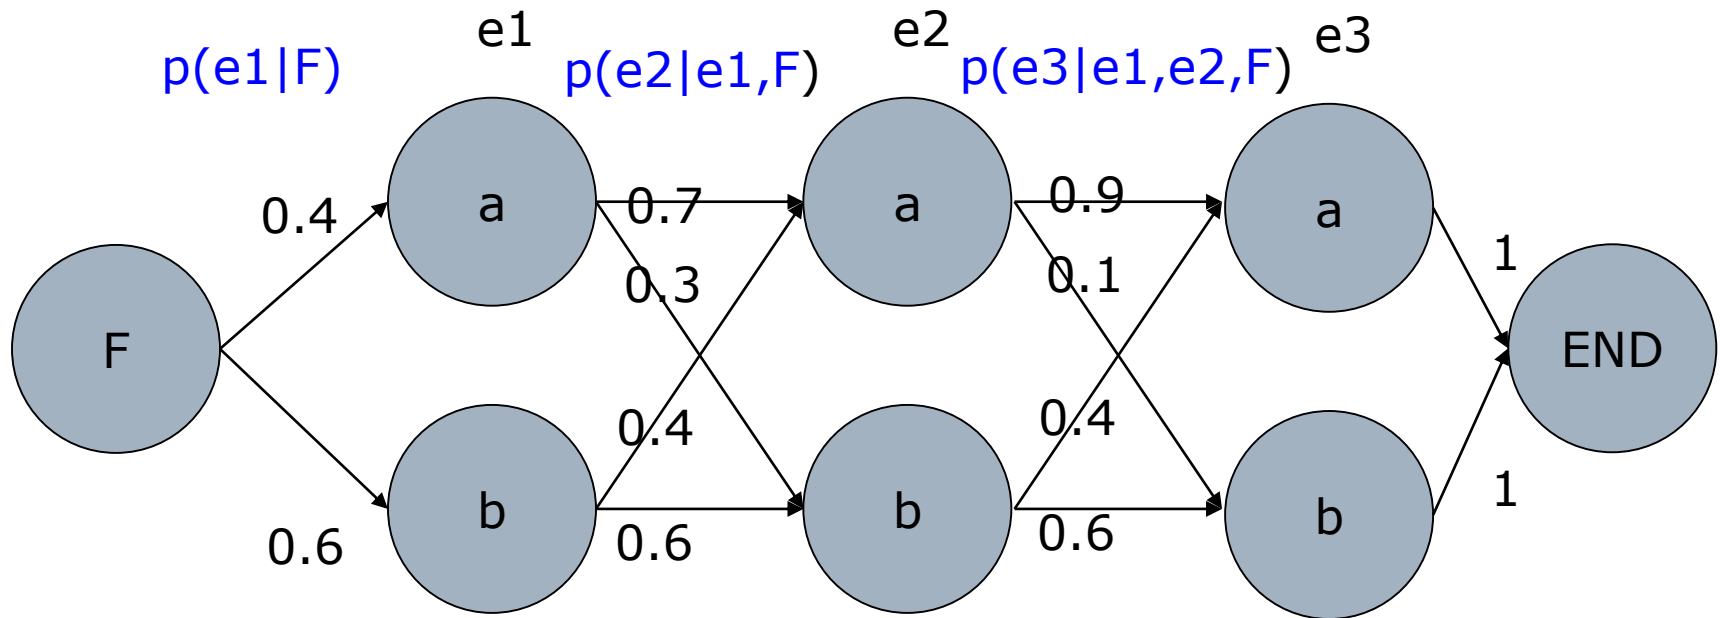
## □ Seq2Seq Model:

- 输入： source sequence
- 输出： target sequence (结构化预测)
- $e_1^N = \operatorname{argmax}_{e_1^N} [\log p(e_1^N | f_1^M)]$ 
  - 搜索空间:  $|V_E|^N$

# Beam Search


□  $V_E = \{a, b\}$

□  $\operatorname{argmax}_{e_1^3} p(e_1, e_2, e_3 | F)?$



# Beam Search

- $\operatorname{argmax}_{e_3} p(e_1, e_2, e_3 | F)$ ?
- 贪心算法：每步都选最大的概率
- $p(b, b, b) = 0.6 * 0.6 * 0.6 = 0.216$



# Beam Search

## Viterbi Algorithm

$s(v, n)$  以 $v$ 结尾的最大概率的sequence的概率


$t(v_1, v_2, n)$  第 $n-1$ 步从 $v_1$ 到第 $n$ 步的 $v_2$ 的概率

动态规划递推公式

$$\max_{e_1} p(e_1, e_2, e_3 | F) = \max\{s(v, 3) | v = 1, \dots, V\}$$

$$s(v = j, n) = \max\{s(v = i, n - 1) * t(i, j, n) | i = 1, \dots, V\}$$

$s(v, n)$	$n = 1$	$n = 2$	$n = 3$
$v = 1$			
$v = 2$			



# Beam Search

$s(v, n)$  以 $v$ 结尾的最大概率的sequence的概率


$t(v_1, v_2, n)$  第 $n-1$ 步从 $v_1$ 到第 $n$ 步的 $v_2$ 的概率

动态规划递推公式

$$\max_{e_1} p(e_1, e_2, e_3 | F) = \max\{s(v, 3) | v = 1, \dots, V\}$$

$$s(v = j, n) = \max\{s(v = i, n - 1) * t(i, j, n) | i = 1, \dots, V\}$$

$s(v, n)$	$n = 1$	$n = 2$	$n = 3$
$v = 1$	0.4(F)		
$v = 2$	0.6(F)		



# Beam Search

$s(v, n)$  以 $v$ 结尾的最大概率的sequence的概率


$t(v_1, v_2, n)$  第 $n-1$ 步从 $v_1$ 到第 $n$ 步的 $v_2$ 的概率

动态规划递推公式

$$\max_{e_1} p(e_1, e_2, e_3 | F) = \max\{s(v, 3) | v = 1, \dots, V\}$$

$$s(v = j, n) = \max\{s(v = i, n - 1) * t(i, j, n) | i = 1, \dots, V\}$$

$s(v, n)$	$n = 1$	$n = 2$	$n = 3$
$v = 1$	0.4(F)	0.28(1)	
$v = 2$	0.6(F)	0.36(2)	



# Beam Search

$s(v, n)$  以 $v$ 结尾的最大概率的sequence的概率


$t(v_1, v_2, n)$  第 $n-1$ 步从 $v_1$ 到第 $n$ 步的 $v_2$ 的概率

动态规划递推公式

$$\max_{e_1} p(e_1, e_2, e_3 | F) = \max\{s(v, 3) | v = 1, \dots, V\}$$

$$s(v = j, n) = \max\{s(v = i, n - 1) * t(i, j, n) | i = 1, \dots, V\}$$

$s(v, n)$	$n = 1$	$n = 2$	$n = 3$
$v = 1$	0.4(F)	0.28(1)	0.252(1)
$v = 2$	0.6(F)	0.36(2)	0.216(2)





# Beam Search

$s(v, n)$  以 $v$ 结尾的最大概率的sequence的概率

$t(v_1, v_2, n)$  第 $n-1$ 步从 $v_1$ 到第 $n$ 步的 $v_2$ 的概率

动态规划递推公式

$$\max_{e_1} p(e_1, e_2, e_3 | F) = \max\{s(v, 3) | v = 1, \dots, V\}$$

$$s(v = j, n) = \max\{s(v = i, n - 1) * t(i, j, n) | i = 1, \dots, V\}$$

$s(v, n)$	$n = 1$	$n = 2$	$n = 3$
$v = 1$	0.4(F)	0.28(1)	0.252(1)
$v = 2$	0.6(F)	0.36(2)	0.216(2)

计算复杂度：  $O(V^2N)$  空间复杂度：  $O(VN)$

加入我们要生成所有一句话的时候，  $V > 40000$

# Beam Search

$s(v, n)$  以 $v$ 结尾的最大概率的sequence的概率

$t(v_1, v_2, n)$  第 $n-1$ 步从 $v_1$ 到第 $n$ 步的 $v_2$ 的概率

动态规划递推公式

$$\max_{e_1} p(e_1, e_2, e_3 | F) = \max\{s(v, 3) | v = 1, \dots, V\}$$

$$s(v = j, n) = \max\{s(v = i, n - 1) * t(i, j, n) | i = 1, \dots, V\}$$


$s(v, n)$	$n = 1$	$n = 2$	$n = 3$
$v = 1$	0.4(F)	0.28(1)	0.252(1)
$v = 2$	0.6(F)	0.36(2)	0.216(2)

计算复杂度：  $O(V^2N)$     空间复杂度：  $O(VN)$

加入我们要生成所有一句话的时候，  $V > 40000$

# Beam Search

## □ Beam Search



# Beam Search

---

□ 大家自己做一遍 Viterbi Algorithm

$s(v, n)$	$n = 1$	$n = 2$	$n = 3$
$v = 1$			
$v = 2$			
$v = 3$			

# Beam Search

---

## □ Beam Search

### ■ Beam Size $B \ll V$

□  $h(b, n)$  在  $(b, n)$  位置的已经生成的sequence

□  $s(b, n) = p(h(b, n))$

### ■ 递推算法：

□ 已知  $s(b, n)$  和  $h(b, n)$ ，求： $s(b, n+1)$ ,  $h(b, n+1)$

□  $\text{temp} = [(h(b, n) + v, p(h(b, n) + v)) \mid b = 1, \dots, B, v = 1, \dots, V]$

□  $\text{temp} = \text{sort}(\text{temp}, \text{key} = \text{lambda } x: [1])$

□  $b(i, n+1), s(i, n+1) = \text{temp}[i], \quad i = 1, \dots, B$

# Beam Search

## □ Beam Search

### ■ beam size = 2

- 已知  $s(b,n)$  和  $h(b,n)$ , 求:  $s(b,n+1), h(b,n+1)$
- $\text{temp} = [(h(b,n)+v, p(h(b,n)+v) \mid b = 1, \dots, B, v=1, \dots, V]$
- $\text{temp} = \text{sort}(\text{temp}, \text{key} = \text{lambda } x: [1])$
- $b(i,n+1), s(i,n+1) = \text{temp}[i], \quad i=1, \dots, B$

$h(b,n), s(b,n)$	$n = 1$	$n = 2$	$n = 3$
$b = 1$	$a, 0.5$		
$b = 2$	$b, 0.3$		

$\text{temp} = [(a, 0.5), (b, 0.3), (c, 0.2)]$

# Beam Search

## □ Beam Search

### ■ beam size = 2

- 已知  $s(b,n)$  和  $h(b,n)$ , 求:  $s(b,n+1), h(b,n+1)$
- $\text{temp} = [(h(b,n)+v, p(h(b,n)+v) \mid b = 1, \dots, B, v=1, \dots, V]$
- $\text{temp} = \text{sort}(\text{temp}, \text{key} = \text{lambda } x: [1])$
- $b(i,n+1), s(i,n+1) = \text{temp}[i], i=1, \dots, B$

$h(b,n), s(b,n)$	$n = 1$	$n = 2$	$n = 3$
$b = 1$	a,0.5	ab, 0.20	
$b = 2$	b,0.3	ac, 0.15	

$\text{temp} = [(aa, 0.5*0.3), (ab, 0.5*0.4), (ac, 0.5*0.3),$   
 $(ba, 0.3*0.4), (bb, 0.3*0.2), (bc, 0.3*0.4)]$

# Beam Search

## □ Beam Search

### ■ beam size = 2

- 已知  $s(b,n)$  和  $h(b,n)$ , 求:  $s(b,n+1)$ ,  $h(b,n+1)$
- $\text{temp} = [(h(b,n)+v, p(h(b,n)+v) \mid b = 1, \dots, B, v=1, \dots, V]$
- $\text{temp} = \text{sort}(\text{temp}, \text{key} = \text{lambda } x: [1])$
- $b(i,n+1), s(i,n+1) = \text{temp}[i], \quad i=1, \dots, B$

$h(b,n), s(b,n)$	$n = 1$	$n = 2$	$n = 3$
$b = 1$	a,0.5	ab, 0.20	aca, 0.105
$b = 2$	b,0.3	ac, 0.15	abb,0.08

$\text{temp} = [(aba, 0.2*0.3), (abb, 0.2*0.4), (abc, 0.2*0.3),$   
 $(aca, 0.15*0.7), (acb, 0.15*0.1), (acc, 0.15*0.2)]$



# Beam Search

---

## □ Beam Search

■ 计算复杂度:  $O(B \log(V)VN)$

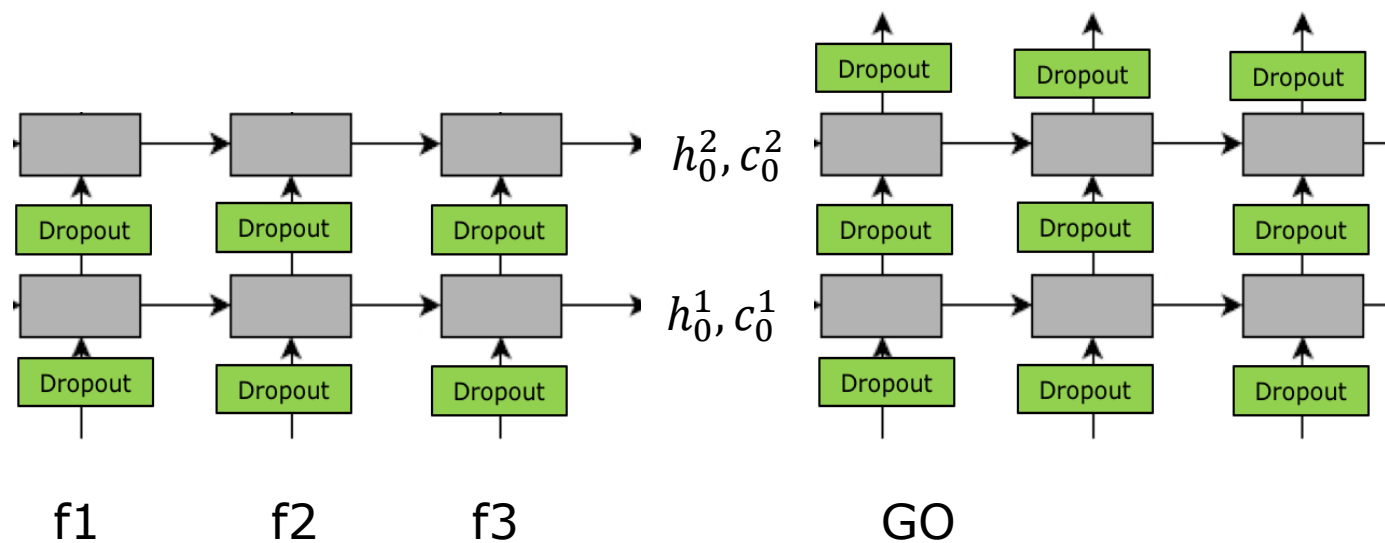
■ 空间复杂度:  $O(BN)$

$h(b,n), s(b,n)$	$n = 1$	$n = 2$	$n = 3$
$b = 1$	a,0.5	ab, 0.20	aca, 0.105
$b = 2$	b,0.3	ac, 0.15	abb,0.08

# Beam Search

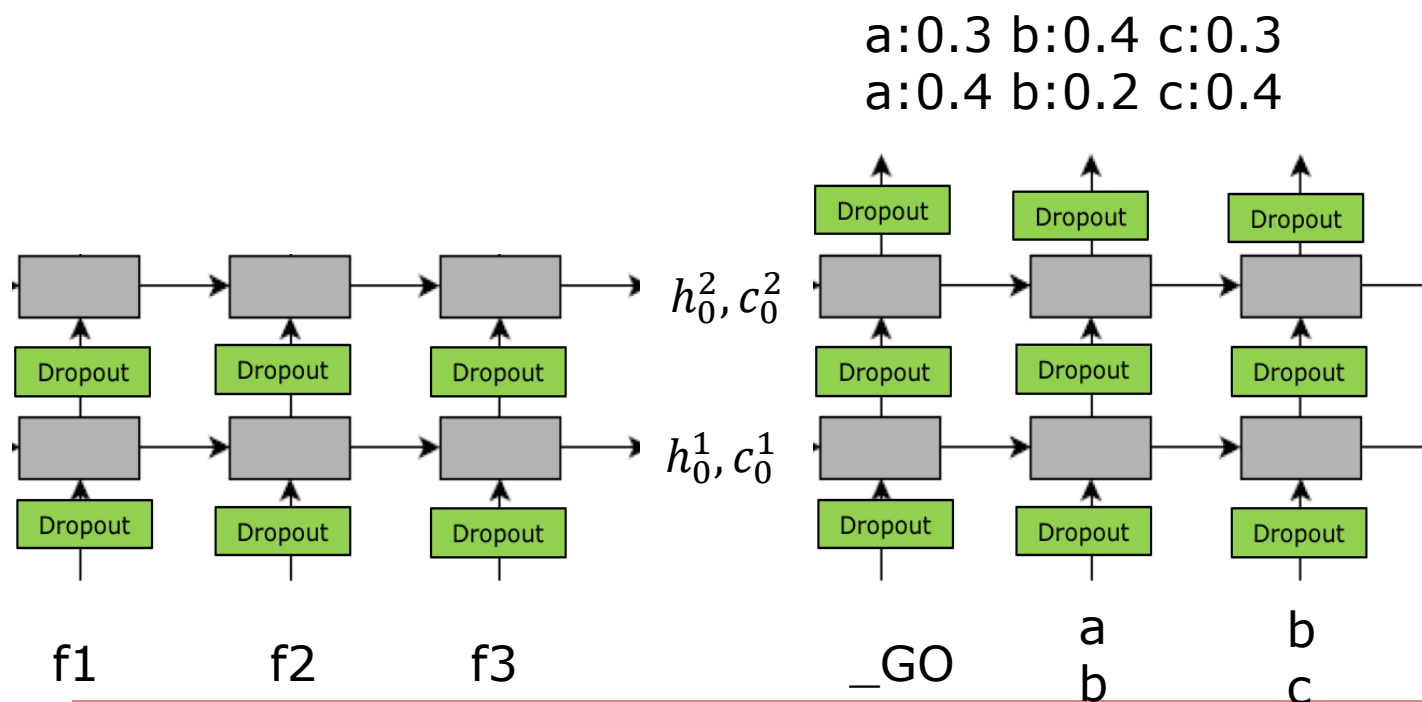
$h(b,n), s(b,n)$	$n = 1$	$n = 2$	$n = 3$
$b = 1$	<b>a,0.5</b>	ab, 0.20	aca, 0.105
$b = 2$	<b>b,0.3</b>	ac, 0.15	abb,0.08

a:0.5 b:0.3 c:0.2



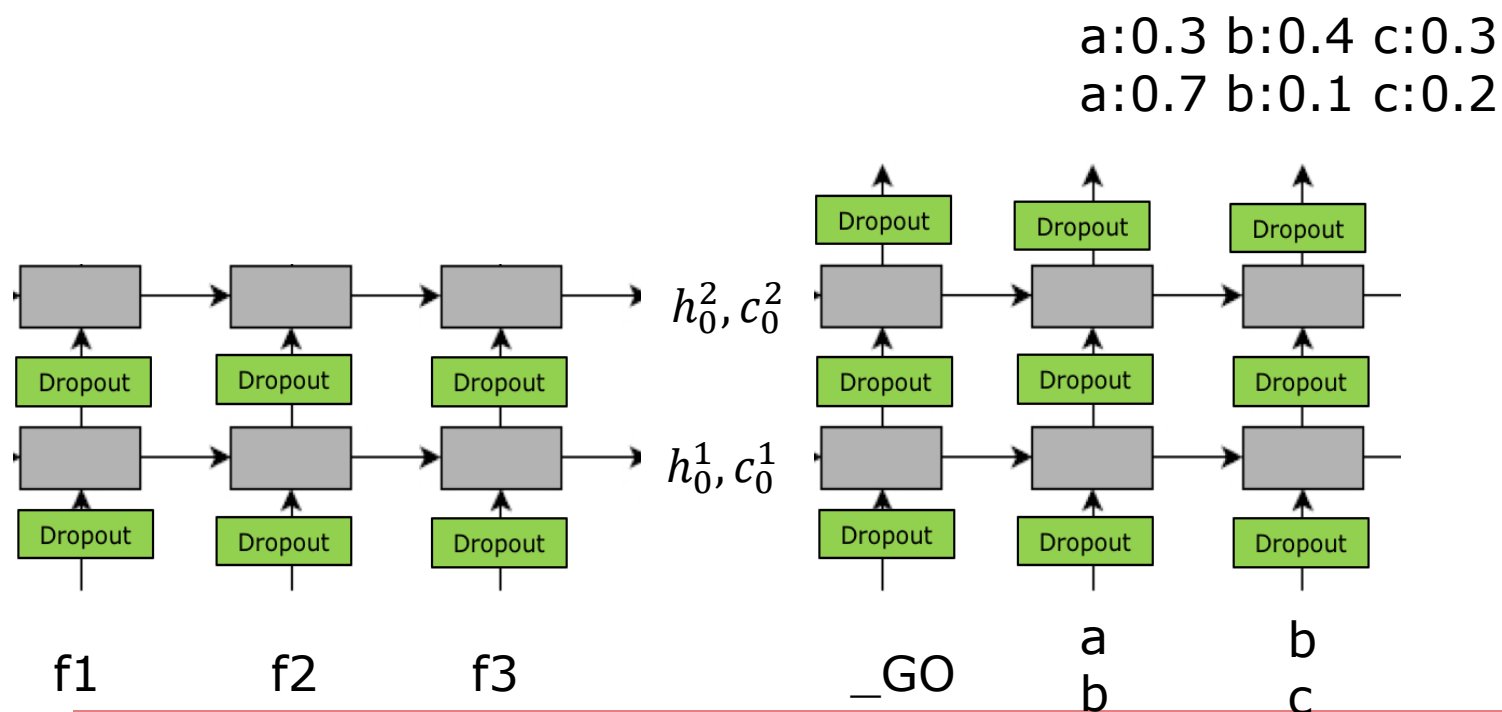
# Beam Search

$h(b,n), s(b,n)$	$n = 1$	$n = 2$	$n = 3$
$b = 1$	a,0.5	ab, 0.20	aca, 0.105
$b = 2$	b,0.3	ac, 0.15	abb,0.08



# Beam Search

$h(b,n), s(b,n)$	$n = 1$	$n = 2$	$n = 3$
$b = 1$	a,0.5	ab, 0.20	aca, 0.105
$b = 2$	b,0.3	ac, 0.15	abb,0.08



# Beam Search

---

## □ 求最大概率路径

### ■ Viterbi Algorithm 全局最优解

□ 计算复杂度  $O(V^2N)$

□ LSTM计算复杂度  $O(VN)$

□ 空间复杂度  $O(VN)$

### ■ Beam Search 近似最优解

□ 计算复杂度  $O(B\log(V)VN)$


□ LSTM计算复杂度  $O(BN)$

□ 空间复杂度  $O(BN)$


### ■ 贪心算法 (Beam Size = 1)

# Attention

- ❑ N-gram 有限的历史 (n)
- ❑ LSTM 无限的历史 ?
- ❑ 以机器翻译为例:



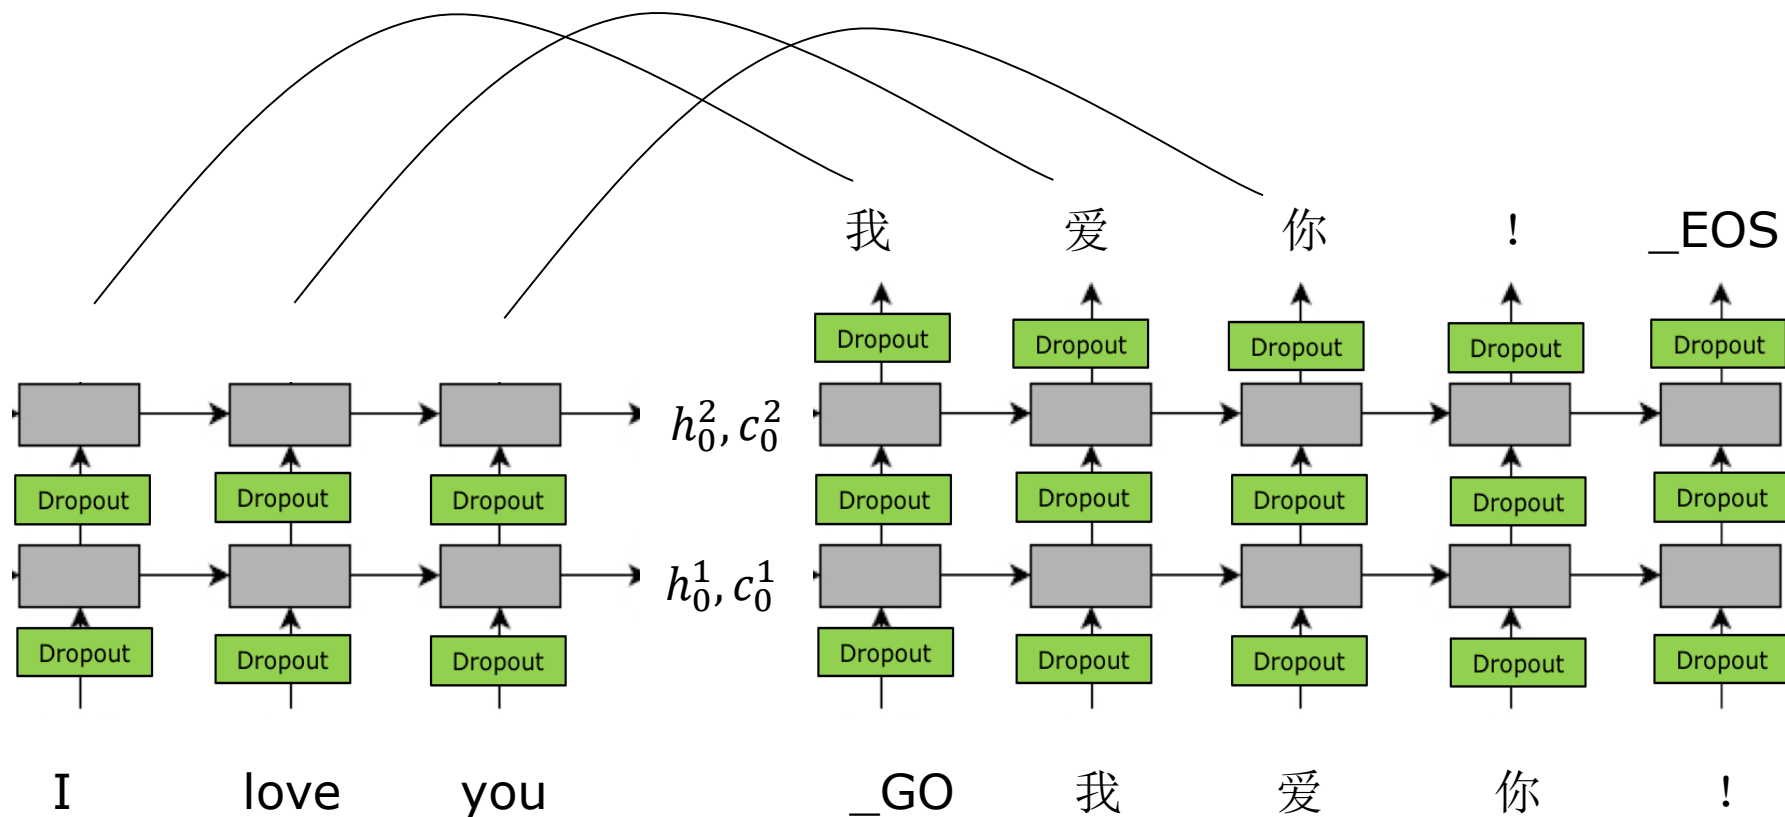
Encoder-Decoder



传统机器翻译

# Attention

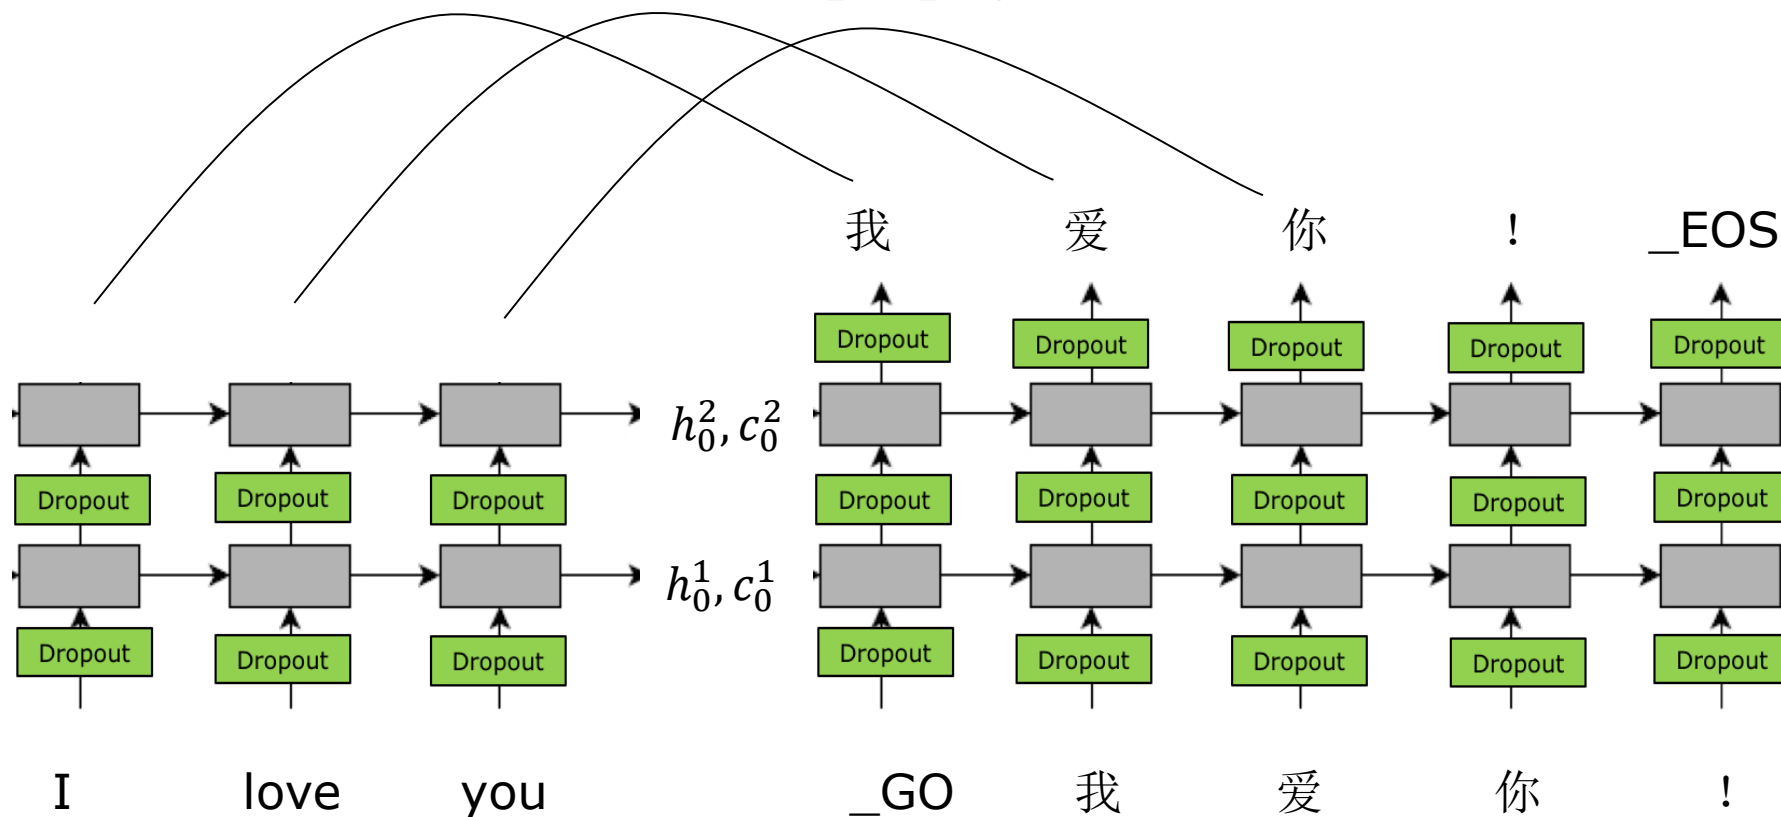
□ 越长距离的关系，LSTM的能力在下降



# Attention

□ 越长距离的关系，LSTM的能力在下降

■ Forward/Backward propagation所要经历的步数

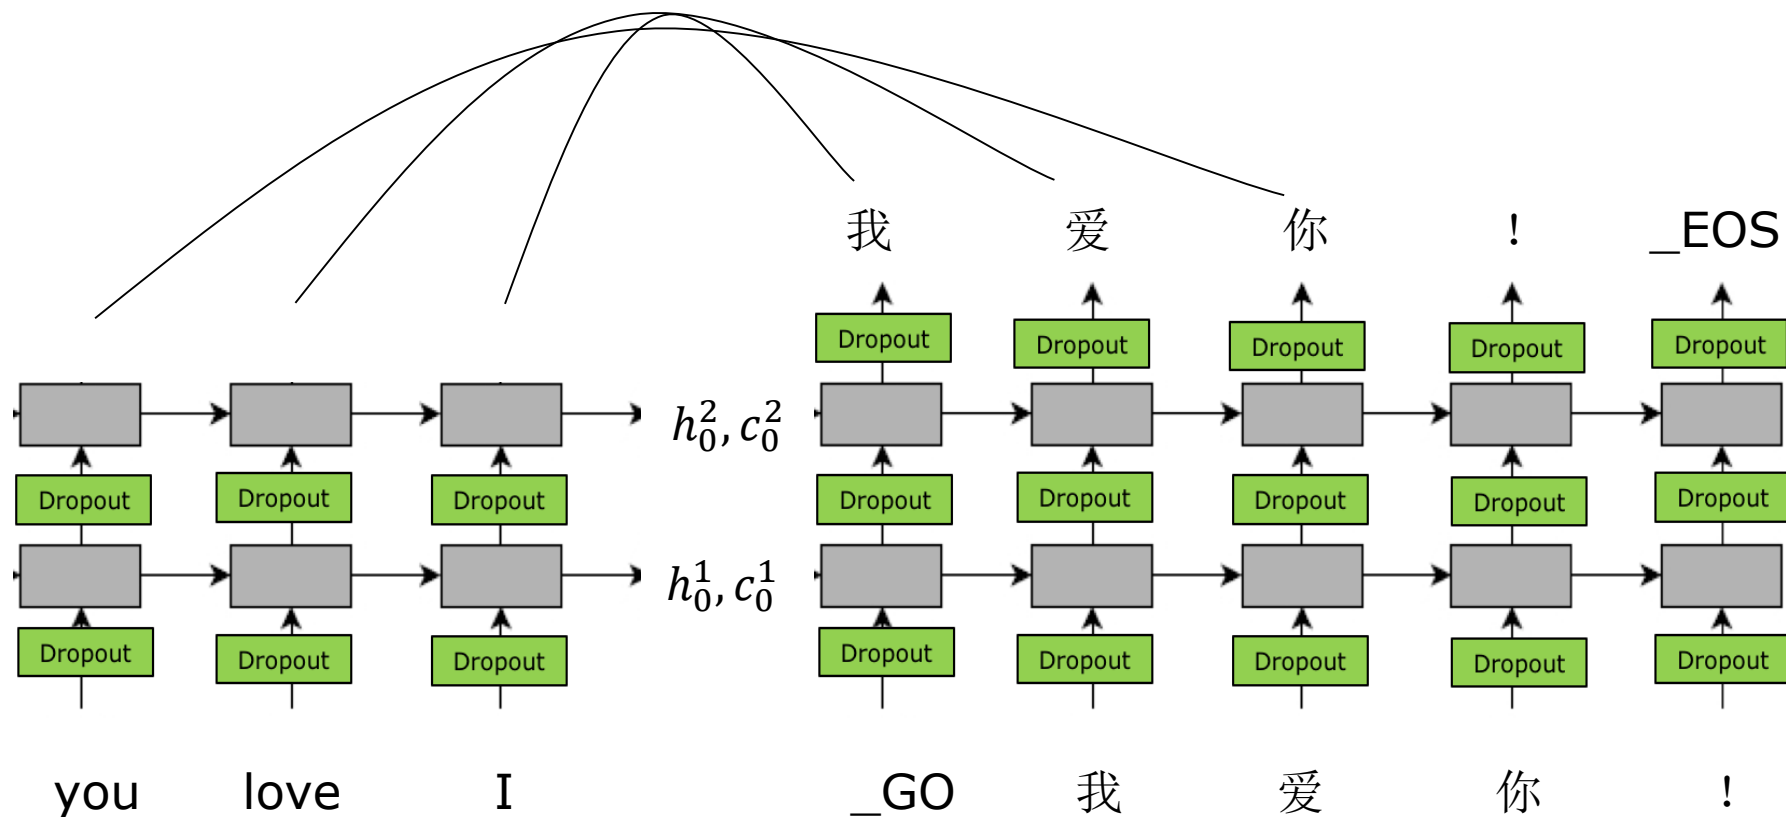




# Attention

□ 越长距离的关系，LSTM的能力在下降

■ 将source sentence倒序输入



# Attention

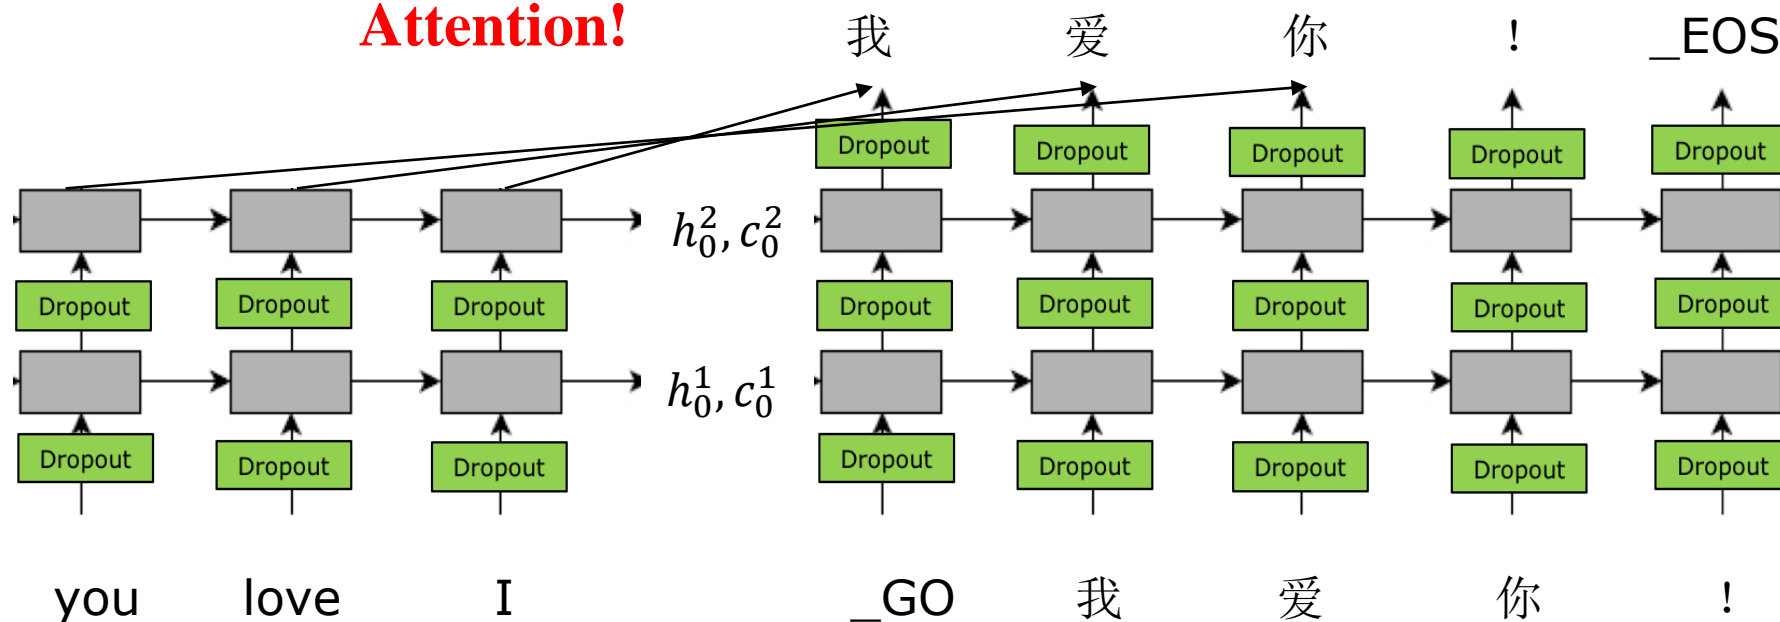
□ 越长距离的关系，LSTM的能力在下降

■ 如何减少B/F propagation的步数？

□ 增加 Skip Connection

□ 如何根据输入和输出动态的选择connection？

**Attention!**



# Attention

## □ Attention

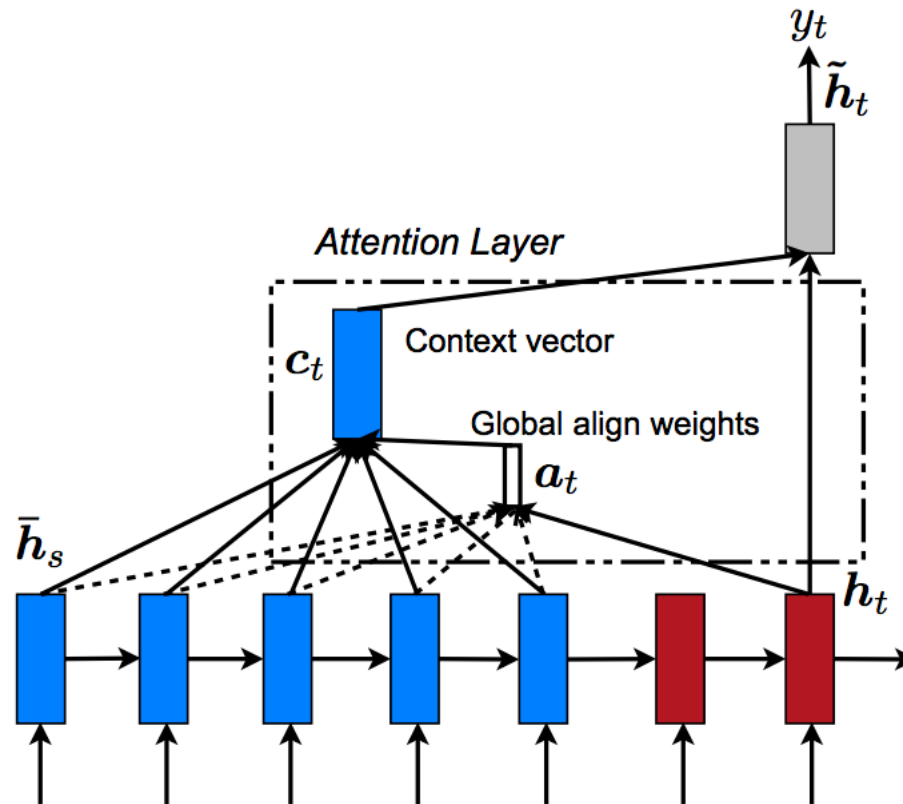


Figure from <https://arxiv.org/pdf/1508.04025.pdf>

# Attention

## □ Attention

$$\text{score}(\mathbf{h}_t, \bar{\mathbf{h}}_s) = \begin{cases} \mathbf{h}_t^\top \bar{\mathbf{h}}_s & \text{dot} \\ \mathbf{h}_t^\top \mathbf{W}_a \bar{\mathbf{h}}_s & \text{general} \\ \mathbf{v}_a^\top \tanh(\mathbf{W}_a [\mathbf{h}_t; \bar{\mathbf{h}}_s]) & \text{concat} \end{cases}$$

$$\mathbf{a}_t = \text{softmax}(\mathbf{W}_a \mathbf{h}_t)$$

$$\begin{aligned} \mathbf{a}_t(s) &= \text{align}(\mathbf{h}_t, \bar{\mathbf{h}}_s) \\ &= \frac{\exp(\text{score}(\mathbf{h}_t, \bar{\mathbf{h}}_s))}{\sum_{s'} \exp(\text{score}(\mathbf{h}_t, \bar{\mathbf{h}}_{s'}))} \end{aligned}$$

本质是Softmax

所以,  $\sum_s \mathbf{a}_t(s) = 1$

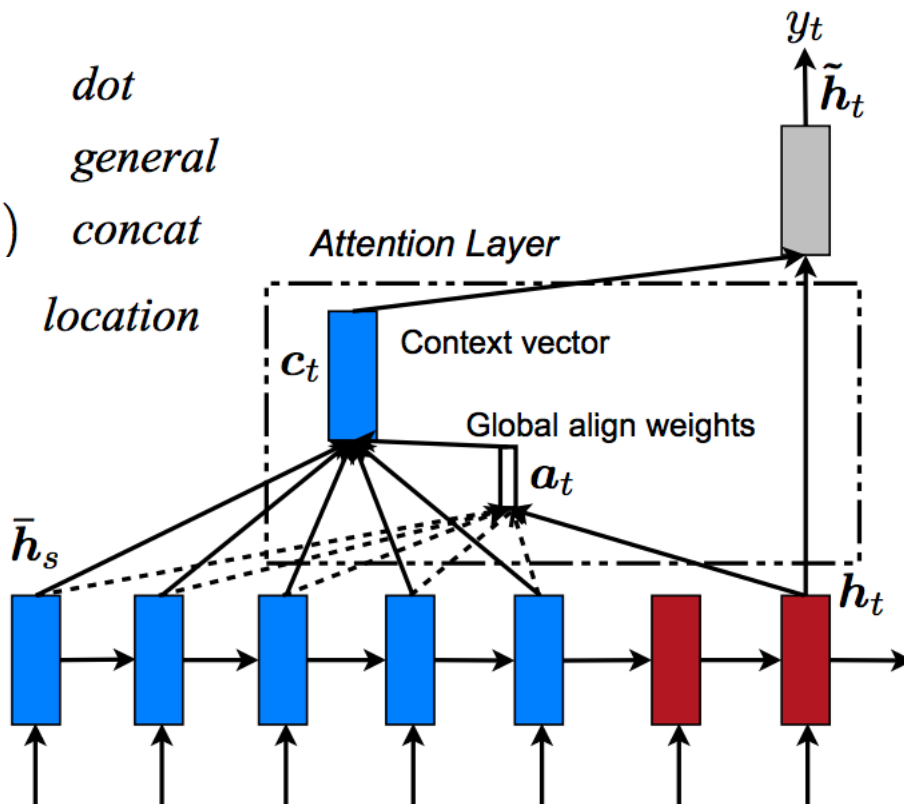


Figure from <https://arxiv.org/pdf/1508.04025.pdf>

# Attention

## □ Attention

$$c_t = \sum_{s'} a_t(s') \bar{h}_{s'}$$

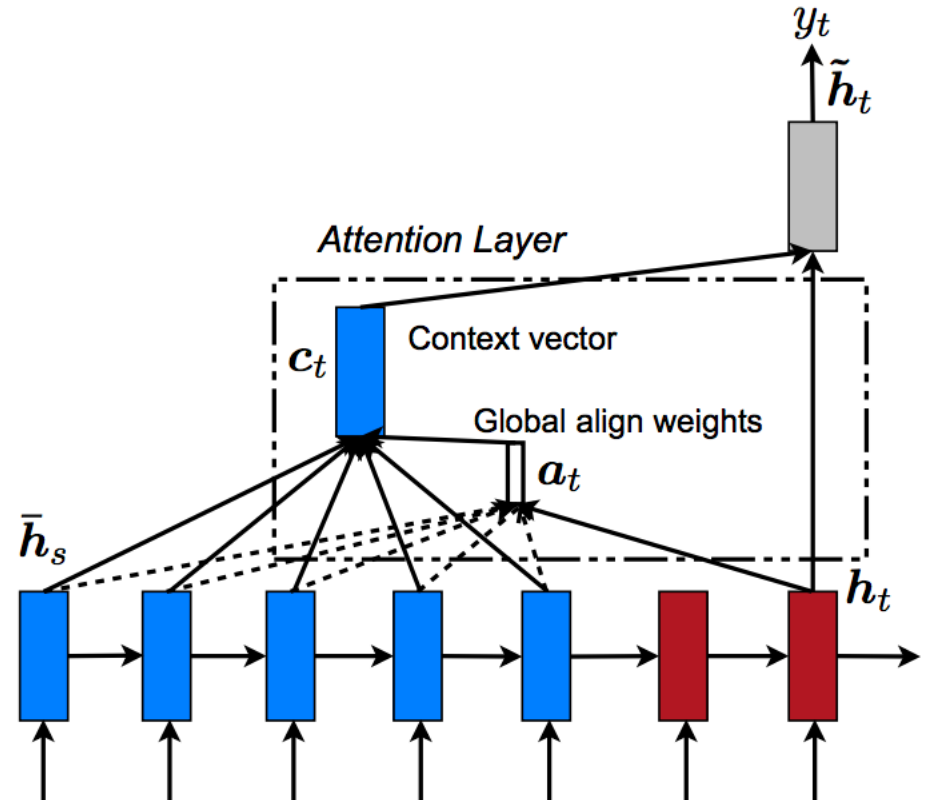


Figure from <https://arxiv.org/pdf/1508.04025.pdf>

# Attention

## □ Attention

$$\tilde{h}_t = \tanh(W_c[c_t; h_t])$$

现在的forward/backward 的path是怎样的？

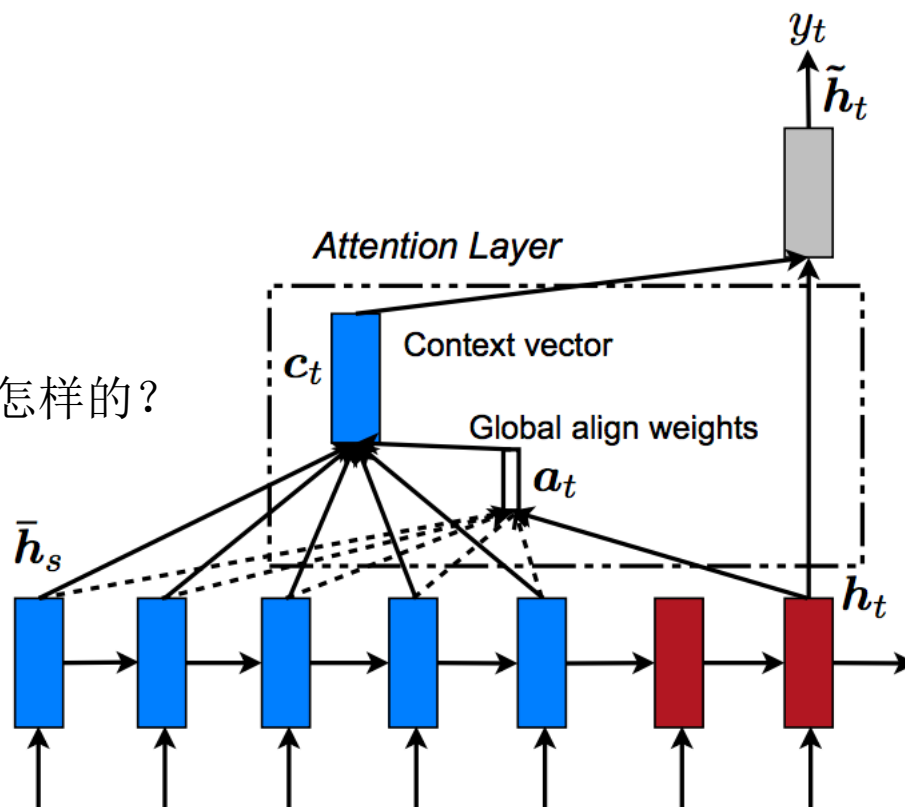


Figure from <https://arxiv.org/pdf/1508.04025.pdf>

# Attention

## □ Attention

- feed-input: 下一个单词知道上一个单词的 attention

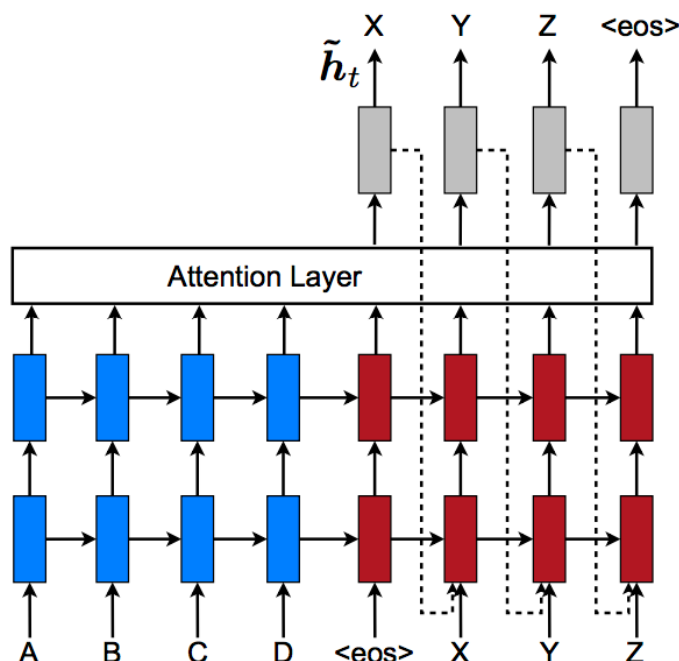


Figure from <https://arxiv.org/pdf/1508.04025.pdf>

# Attention

## □ Seq2Seq的技巧总结：

■ dropout + reverse + attention + feed-input

System	Ppl	BLEU
Winning WMT'14 system – <i>phrase-based</i> + <i>large LM</i> (Buck et al., 2014)		20.7
Base	10.6	11.3
Base + reverse	9.9	12.6 (+1.3)
Base + reverse + dropout	8.1	14.0 (+1.4)
Base + reverse + dropout + global attention ( <i>location</i> )	7.3	16.8 (+2.8)
Base + reverse + dropout + global attention ( <i>location</i> ) + feed input	6.4	18.1 (+1.3)

Figure from <https://arxiv.org/pdf/1508.04025.pdf>



# 联系我们

---

## 小象学院：互联网新技术在线教育领航者

- 微信公众号：大数据分析挖掘
- 新浪微博：ChinaHadoop

