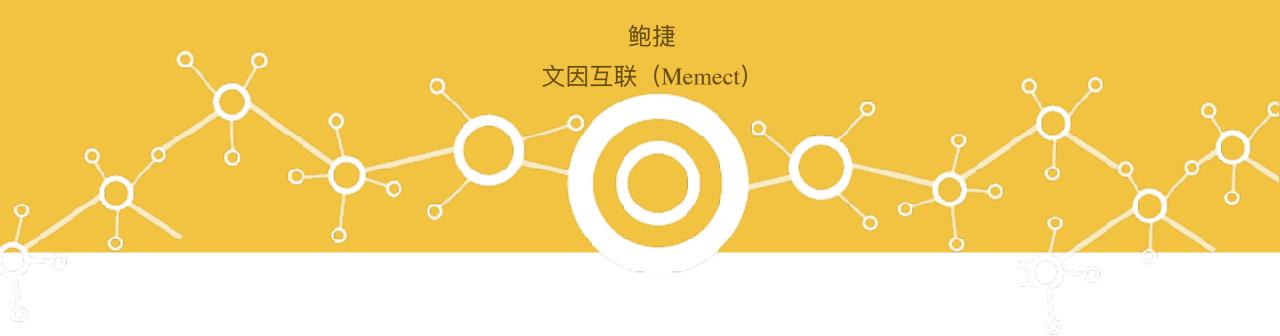




## 知识图谱发展史



## 个人简介

- 2001-2007 lowa State University, PhD
- 2008-2010
   Rensselaer Polytechnic Institute (RPI),
   TetherlessWord Constellation, PostDoc
- 2010-2011
   MIT and BBN,
   visiting researcher
- 2011-2013
   Samsung Research USA
- 2013-now, Memect (San Jose, CA)
   文因互联(Beijing)

Description Logic, Ontology Building

Semantic wiki, **OWL** working group, ontology formal semantics

Information theory, financial ontology, policy language

Question answering, NLP

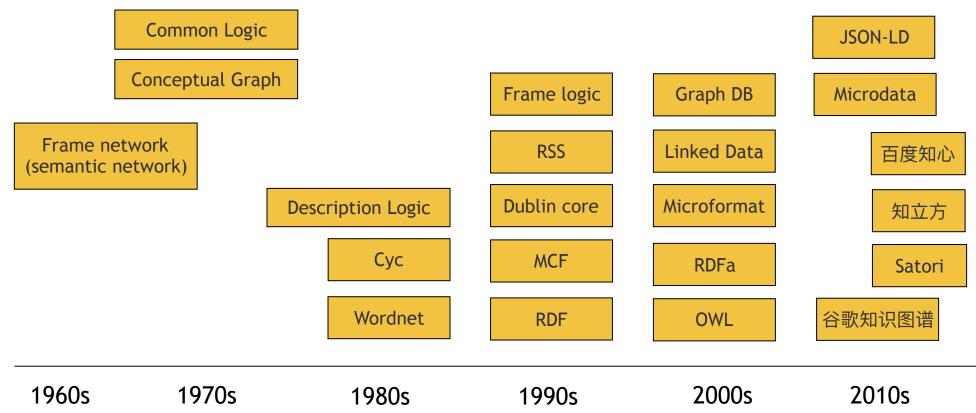
好东西传送门 金融知识图谱

## 什么是知识图谱

- Wikipeia: The Knowledge Graph is a knowledge base used by Google to enhance its search engine's search results with semantic-search information gathered from a wide variety of sources.
  - <u>Google知识图谱</u>(英语:Google Knowledge Graph,也称Google知识图)是Google的一个知识库,其使用语义检索从多种来源收集信息,以提高Google搜索的质量。
- 维基百科: <u>知识库</u>是用于知识管理的一种特殊的数据库,以便于有关领域知识的采集、整理以及提取。知识库中的知识源于领域专家,它是求解问题所需领域知识的集合,包括基本事实、规则和其它有关信息。
- 王昊奋: <u>知识图谱</u>旨在描述真实世界中存在的各种实体或概念。其中,每个实体或概念用一个全局唯一确定的ID来标识,称为它们的标识符。每个属性-值对用来刻画实体的内在特性,而关系用来连接两个实体,刻画它们之间的关联。

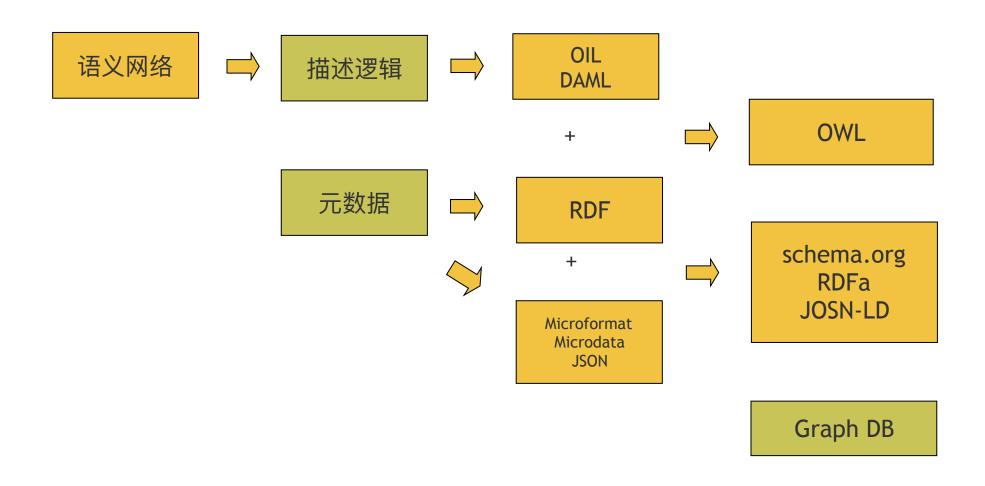
## 知识图谱的前身

### (非完备列表)

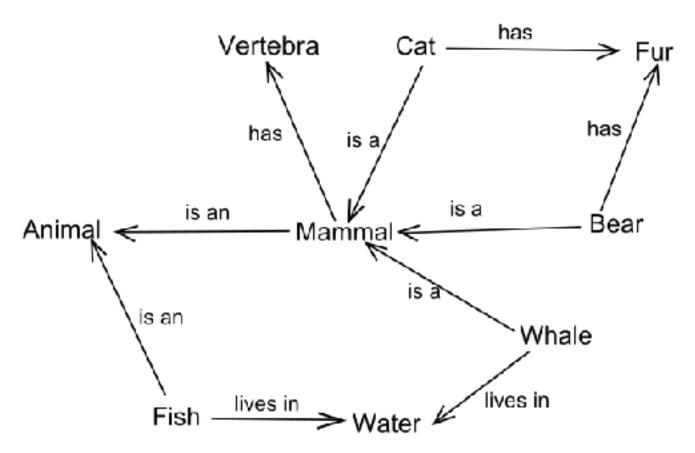


4

# 知识图谱的演化 (简化)



## 语义网络 Semantic Network (Frame Network)



1960s, 由Robert F. Simmons, M. Ross Quillian, Allan M. Collins 等人发展 被批评缺少"语义",不能用于推理

## 描述逻辑 Description Logic

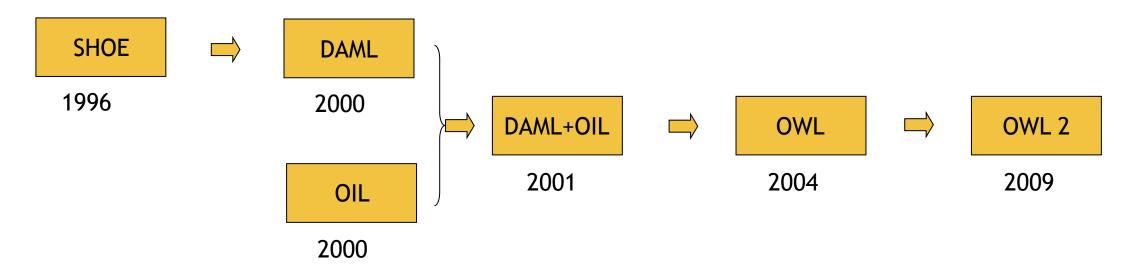
DL	FOL
$A \sqcup B$	$A(x) \vee B(x)$
$\neg A$	$\neg A(x)$
$A \sqcap B$	$A(x) \wedge B(x)$
$a:A\sqcap B$	$A(a) \wedge B(a)$
$\exists P.A$	$\exists (y)(P(x,y)\vee A(y))$
$\forall P.A$	$\forall (y)(P(x,y) \Rightarrow A(y)$
(a,b): P, P(a,b), aPb	P(a,b)
$A \sqsubseteq B$	$\forall (x)(A(x) \Rightarrow B(x)$
A = B	$\forall (x)(A(x) \Leftrightarrow B(x)$
$P \sqsubseteq R$	$\forall (x,y)(P(x,y) \Rightarrow R(x,y))$
$R = P^-, R = Inv(P)$	$\forall (x,y)(P(x,y) \Rightarrow R(y,x)$

图片 by Bijan Parsia http://www.cs.man.ac.uk/-bparsia/2006/cs30411/19-10-fol-2-dls.html

提供了严格的"语义"(基于<u>开放世界假设</u>)以支持推理。 可看作一阶逻辑的可判定子集

### OWL

#### 描述逻辑的HTML或XML语法



- · OWL提供了一组适合Web传播的描述逻辑的语法。
- 其开放世界语义当初被认为适合刻画Web的开放性
- 但其认知复杂性限制了它的工程应用

## W3C OWL工作组

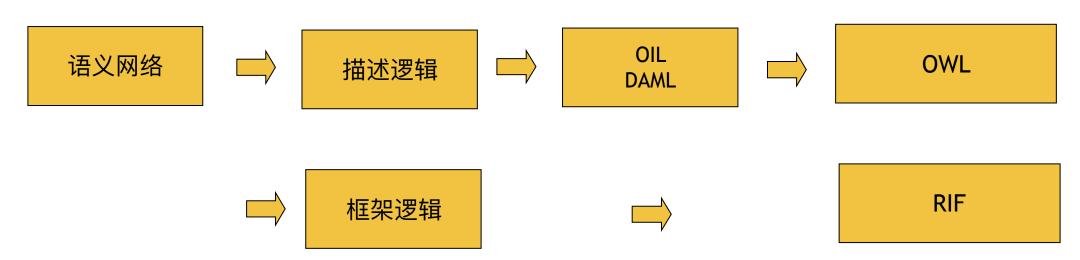
- 2007-2010
- ~40 成员,~20活跃成员,http://www.w3.org/2007/OWL/wiki/Participants
- •大学为主,企业成员主要有IBM,Oracle,HP,Clark & Parsia
- 产生了10+个文档, 600+页

## 工作组遇到的问题

- 路线问题: SEMANTIC Web or semantic WEB
  - logic vs data
  - RDFS++ vs SROIQ
  - 表达力 vs 可用性
- 三种复杂性: 计算复杂性, 认知复杂性, 工程复杂性
- 缺少企业参与, 缺少来自真实用户的需求
- 文档和工具系统脱离一线程序员,得不到支持和应用

## 小结: 从弱语义到强语义的尝试 (逻辑)

(已经很像今天的知识图谱了)



## 元数据框架到RDF

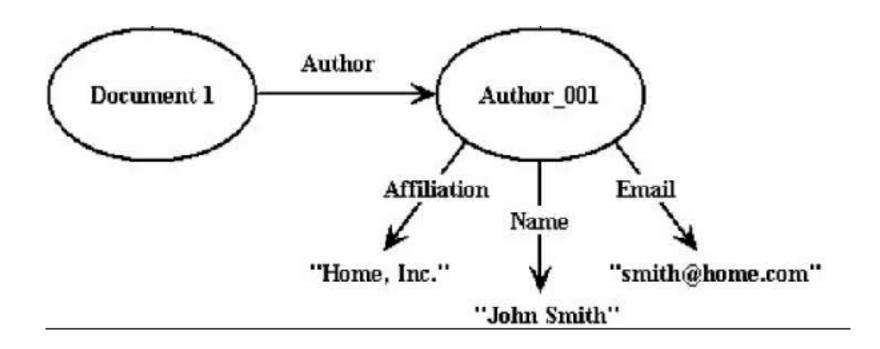
RDF Site Summary
1999, Libby and Guha
Netscape

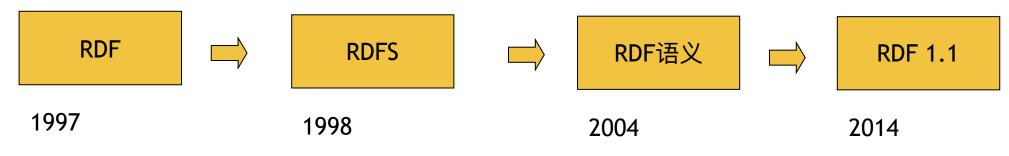
RDF/XML RDF as
W3C rec

Meta Content Framework
1995, Guha
Apple
Resource Decription Framework
1997, Guha, Tim Bray
Netscape

- RDF是从实践中bottom-up总结出来的
  - OWL是一种top-down设计
- RDF的基础是三元组(triple)
- Guha也是Google知识图谱的主要推手

### RDF



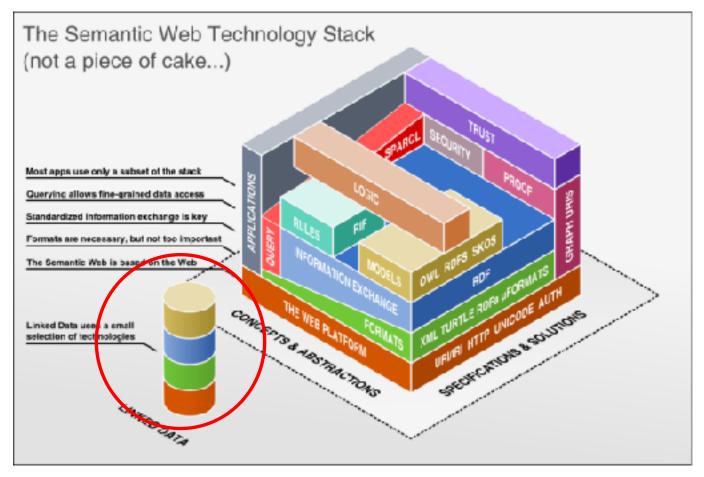


## 小结: 从弱语义到强语义的尝试 (元数据)

- RDF开始是一个没有语义的元数据框架
- 因为推理的需要加上了语义
- 为了和OWL统一,两个语言都采用了复杂的模型论语义,支持了基于规则的推理
- 但在实践中,推理很少被实用。大部分场合下RDF只是被用为一种数据描述语言

## 关联数据 Linked Data

到了2006年, 语义网技术堆栈又已经复杂到没多少人看得懂了, 于是:



## 关联数据 Linked Data

Tim Berners-Lee

Date: 2006-07-27, last change: \$Date: 2009/06/18 18:24:33 \$ Status: personal view only. Editing status: imperfect but published.

Up to Design Issues

#### **Linked Data**

The Semantic Web isn't just about putting data on the web. It is about making links, so that a person or machine can explore the web of data. With linked data, when you have some of it, you can find other, related, data.

Like the web of hypertext, the web of data is constructed with documents on the web. However, unlike the web of hypertext, where links are relationships anchors in hypertext documents written in HTML, for data they links between arbitrary things described by RDF,. The URIS identify any kind of object or concept. But for HTML or RDF, the same expectations apply to make the web grow:

- Use thus as names for things.
- 2. Use HITP URB so that people can look up those names.
- 3. When someone looks up a URI, provide useful information, using the standards (RDI\*, SPARQL)
- Include links to other URIs, so that they can discover more things.

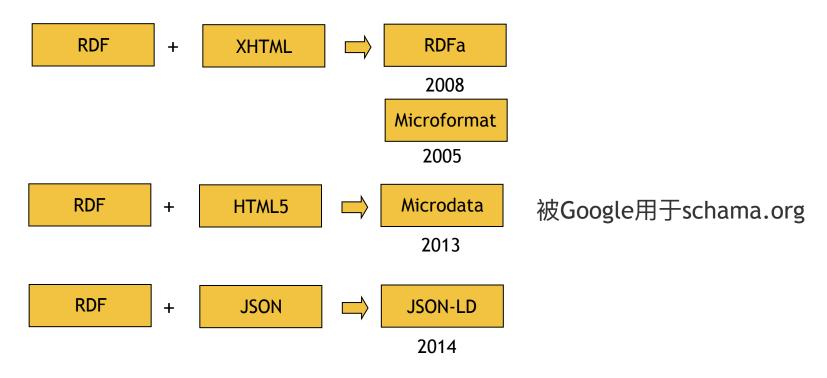


Cimple. In fact though a suppositing amount of data ignit limited in 2000 because of problems with any anymous of the stone. This

## 小结: 从强语义到弱语义的尝试 (关联数据)

- 关联数据是在前期(2001-2006)失败的基础上,做了对工程友好的调整和简化
- RDF作为数据交换语言,并不意味着需要同时作为数据存储语言,或者数据建模语言。
- 互联是第一位的,数据质量、发布者世界观的统一(本体)可以按需提高
- 产生了较大的影响,例如IBM Waston、美国政府开放数据

## 新的综合: 交換语言



依托于成熟的Web交换语言(HTML, JSON),充分利用现有工具,让普通程序员、站长容易理解和使用。

至少30%的网页已经有某些语义元数据(根据Web Data Commons统计http://webdatacommons.org/)

## 新的综合:存储语言(图数据库)



#### Google知识图谱

- ·以Freebase为基础
- · 图数据库内部存储(早期有graphd,Cayley)



#### 微软Satori

- · 图数据库内部存储(Trinity,Graph Engine)
- · 底层是key-value store

## 新的综合:存储语言(图数据库)



- 两种图建模:RDF图和属性图 (Property Graph)有融合的趋势
- 推理可以看成图上的遍历和构造
- 属性图标准Tinkerpop已 经获得很大的市场成功

## 小结: 从强语义到弱语义的尝试 (图数据库)

- 从顶向下设计的RDF数据库没有从底向上设计的图数据库成功
- 新的大型知识图谱数据库大多是图数据库,底层可能是键值数据库、内存数据库、列数据库等
- 不追求严格的模型论语义,而面向查询定义过程语义,或不追求语义

### Lean Semantic Web

- https://github.com/baojie/leansemanticweb
- 瘦语义网的几点想法 http://baojie.org/blog/2013/01/24/lean-semantic-web/
- 从大数据到小数据 http://baojie.org/blog/2015/04/05/from-big-data-to-small-data/
- 我对关联数据的看法 http://baojie.org/blog/2014/12/21/on-linked-data/
- 关于知识管理和语义搜索的一些思考 http://baojie.org/blog/2015/03/04/on-knowledge-management/
- 语义网的工具演化 http://baojie.org/blog/2014/02/12/semantic-tool-evolution/

## 总结

- 第一阶段: 从弱语义到强语义 (pre-2006)
  - 从语义网络,到描述逻辑,到OWL
  - 从元数据框架,到RDF,到RDFS
- 第二阶段: 从强语义再到弱语义(2006-至今)
  - 关联数据,和现有Web工业常用标准的结合
  - 从RDF数据库到图数据库
- 20年来的历史表明
  - 从实践中总结(JSON,图数据库等)优于从顶向下的设计
  - 充分和现有工具系统的兼容优于全新框架
  - 简单优于强大

## 展望

- 知识图谱会快速向多个垂直领域渗透,如医疗、电商、金融、投资等。弱语 义的趋势短期还会延续,可能针对这些领域做进一步的简化
- 发展非Entity-Relation的建模方式,概率的、模糊的关联,综合DB和IR系统,降低知识表现全周期成本
- 数据交换语言和数据存储语言的分离可能会持续。图数据库将成为主要的存储语言和工具
- 标准的产生可能由以W3C主导转变为以Web公司为主导,再由标准化组织总结

### 推荐资料

#### **The Semantic Web**

#### 知识表示 + 知识推理

- RDF: <a href="https://www.w3.org/TR/2004/REC-rdf-primer-20040210/">https://www.w3.org/TR/2004/REC-rdf-primer-20040210/</a>
- RDFa: <a href="https://www.w3.org/TR/rdfa-core/">https://www.w3.org/TR/rdfa-core/</a>
- JSON-LD: <a href="https://www.w3.org/TR/2014/REC-json-ld-20140116/">https://www.w3.org/TR/2014/REC-json-ld-20140116/</a>
- RDFS: <a href="https://www.w3.org/TR/2014/REC-rdf-schema-20140225/">https://www.w3.org/TR/2014/REC-rdf-schema-20140225/</a>
- OWL:
  - https://www.w3.org/TR/2004/REC-owl-features-20040210/
  - o https://www.w3.org/TR/2012/REC-owl2-primer-20121211/
- Prov:https://www.w3.org/TR/prov-overview/
- More Inference & Reasoning:
  - RIF: <a href="https://www.w3.org/TR/2013">https://www.w3.org/TR/2013</a> TE-rif-primer-20130205/
  - SPARQL based reasoning: <a href="http://vos.openlinksw.com/owiki/wiki/VOS/VirtSPARQLReasoningTutorial">http://vos.openlinksw.com/owiki/wiki/VOS/VirtSPARQLReasoningTutorial</a>
  - Description Logic Primer: <a href="https://arxiv.org/abs/1201.4089">https://arxiv.org/abs/1201.4089</a>

#### 知识检索

- SPARQL: <a href="https://www.w3.org/TR/sparql11-overview/">https://www.w3.org/TR/sparql11-overview/</a>,
- Tools: <a href="https://www.w3.org/2001/sw/wiki/SPARQL">https://www.w3.org/2001/sw/wiki/SPARQL</a>

### 知识抽取

- Information Extraction: <a href="https://web.stanford.edu/~jurafsky/slp3/21.pdf">https://web.stanford.edu/~jurafsky/slp3/21.pdf</a>
- NER: <a href="http://www.cfilt.iitb.ac.in/resources/surveys/rahul-ner-survey.pdf">https://nlp.cs.nyu.edu/sekine/papers/li07.pdf</a>
- Entity Linking: <a href="http://dbgroup.cs.tsinghua.edu.cn/wangjy/papers/TKDE14-entitylinking.pdf">http://dbgroup.cs.tsinghua.edu.cn/wangjy/papers/TKDE14-entitylinking.pdf</a>

25



## backup

## 什么是知识表现 (Knowledge Representation)

- •知识是什么?
- 如何用计算机储存知识?
- 如何从已知的知识推导出未知的知识?

# 知识就是结构

## OWL的语义

http://www.slideshare.net/baojie\_iowa/2008-0906-owl-full-semantics

#### **OWL Full Semantics**

RDF-Compatible Model-Theoretic Semantics

by Peter F. Patel-Schneider, Patrick Hayes and Ian Horrocks W3C Recommendation, 2004

http://www.w3.org/TR/owl-semantics/rdfs.html

Presented by Jie Bao RPI Sept 11, 2008

Part 2 of RDF/OWL Semantics Tutorial http://tw.rpi.edu/wiki/index.php/RDF and OWL Semantics

## RDF语义

http://www.slideshare.net/baojie\_iowa/rdf-semantics

#### **RDF Semantics**

by Patrick Hayes W3C Recommendation

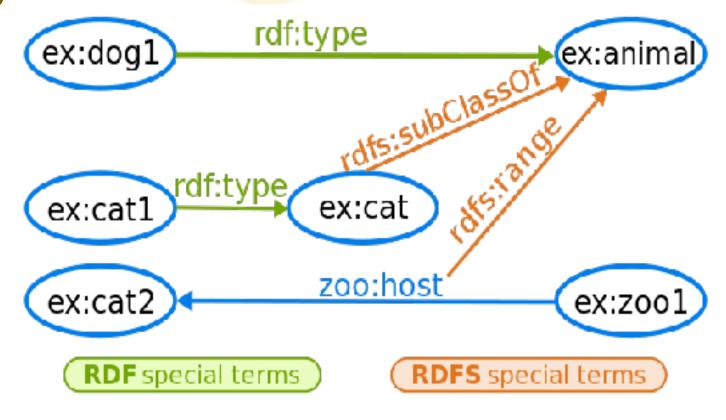
http://www.w3.org/TR/rdf-mt/

Presented by Jie Bao RPI Sept 4, 2008

Part 1 of RDF/OWL Semantics Tutorial http://tw.rpi.edu/wiki/index.php/RDF and OWL Semantics

RDF引入(一个高阶的可能会产生悖论的)语义也许是一个错误!

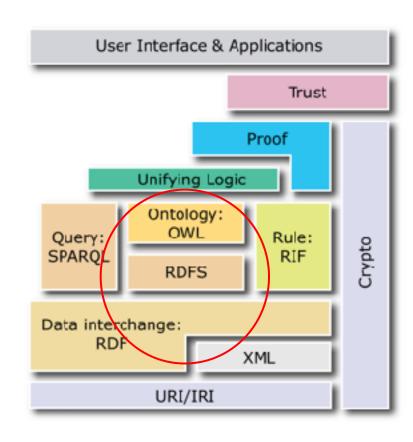
### **RDFS**



图片来自 https://en.wikipedia.org/wiki/RDF\_Schema

RDF只提供了概念和关系的基本描述能力,并没有推理的能力。 RDFS则提供了简单的推理"schema"

# RDF和OWL的关系



by Jie Bao, 2008

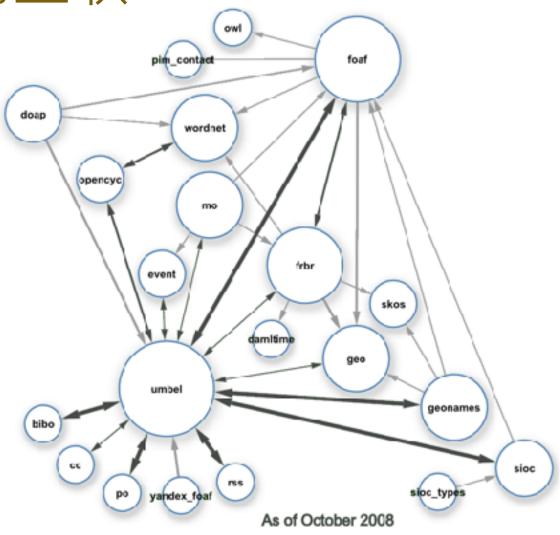
## 框架逻辑 F-Logic

man::person.
woman::person.
brad:man.
angelina:woman.
person[hasSon=>man].
brad[hasSon->>{maddox,pax}].
married(brad,angelina).
man(X) <- person(X) AND NOT woman(X).</pre>

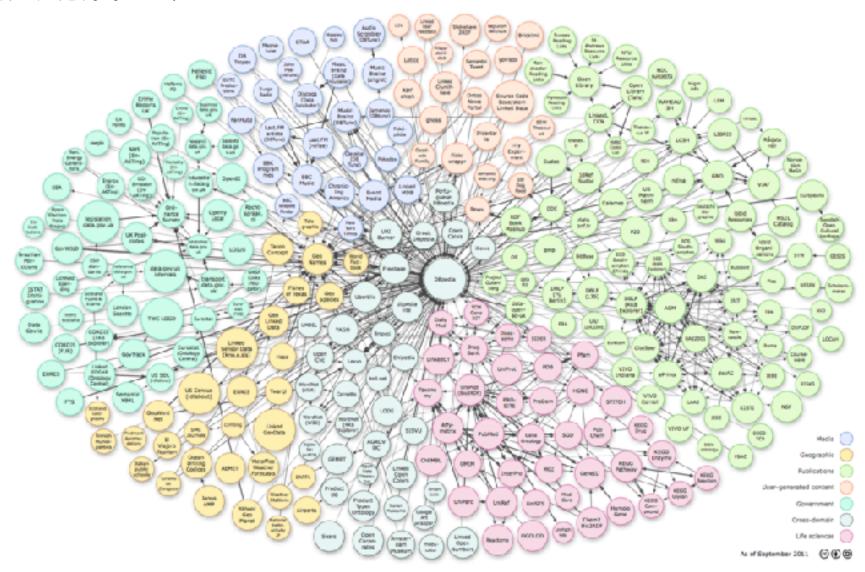
提供了另一种严格的"语义"(基于<u>封闭世界假设</u>)以支持推理。可看作一阶逻辑的一个不可判定子集

当初(2000s)很有希望成为本体语言的基础,但是Horrocks太勤快了 ...... 好在后来在RIF中得到了体现

## 基于URI的互联



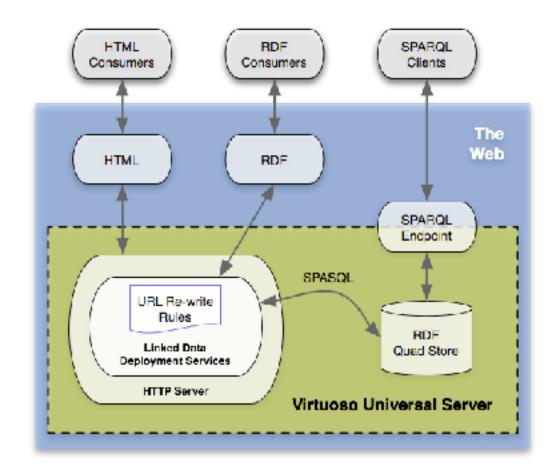
# 互联数据云



## DBpedia



- 从wikipedia抽取
- 英文版有4.58m个实体
  - 1,445,000 人
  - 735,000 地点
  - 123,000 音乐专辑
  - 87,000 电影
  - 241,000 组织
  - 251,000 物种
  - 6,000 疾病
  - 等等
- 基于RDF/SPARQL

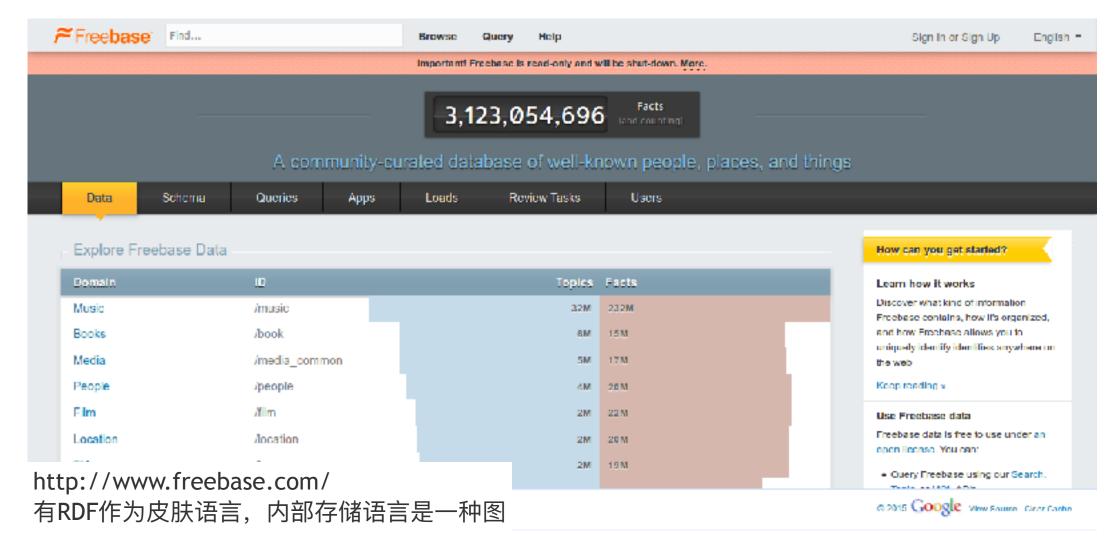


http://wiki.dbpedia.org/about/about-dbpedia/architecture

## 开放政府数据



# Freebase







主页: www.memect.cn 微博: weibo.com/wenyinhulian 邮箱: contact@memect.co