

# 面向大规模知识图谱的智能问答

周光有



视频直播地址

## □ 知识图谱概述

- 知识图谱简介
- 知识表示学习
- 知识图谱应用

## □ 知识库问答系统

- 知识库问答简介
- 知识库问答方法
- 知识库问答与知识图谱

## □ WIKIPEDIA

- A knowledge base (KB) is a technology used to store complex structured and unstructured information used by a computer system. The initial use of the term was in connection with expert systems which were the first knowledge-based systems.

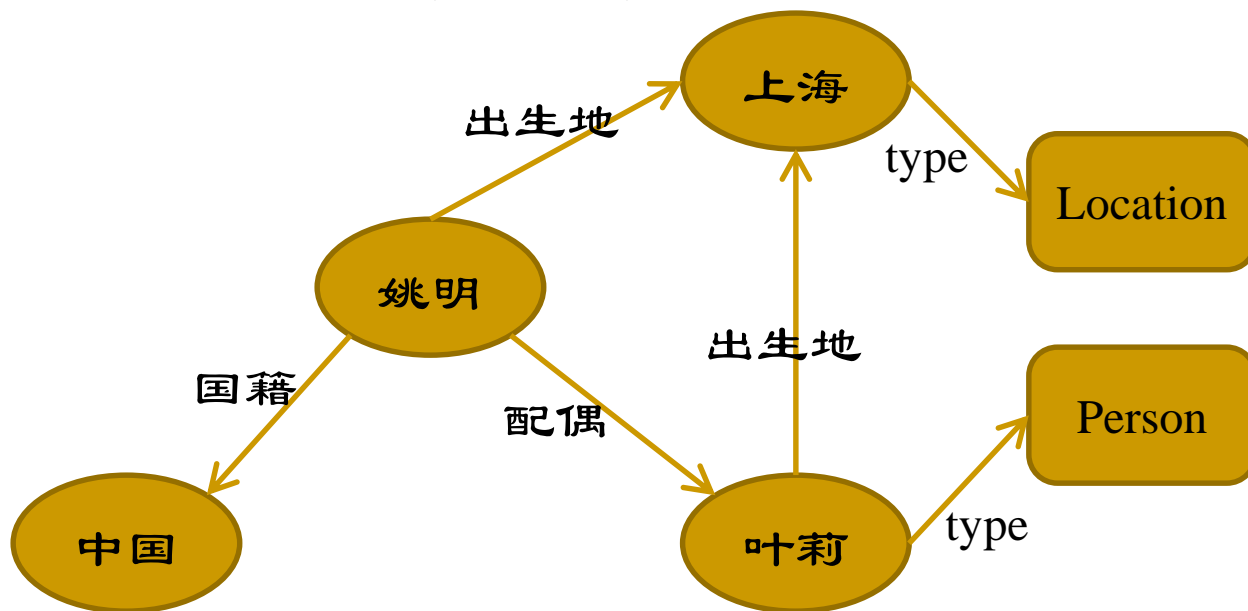
## □ 定义

- 知识图谱旨在描述真实世界中存在的各种实体或概念及其关系, 其构成一张巨大的语义网络图, 节点表示实体或概念, 边则由属性或关系构成。
- 现在的知识图谱已被用来泛指各种大规模的知识库。
- 如Freebase, DBpedia, YAGO, NELL等。

# 知识图谱简介

## □ 构成：三元组

- 知识图谱由大量三元组构成。
- 三元组由（头节点，关系，尾节点）构成。



## □ 知识图谱表示

- 传统的知识表示方法主要以三元组来描述实体之间的关系。这种方法通用简单，但存在计算效率低，数据稀疏等问题。
- 近年来，以深度学习为代表的**知识表示学习**取得了重要进展，表示学习旨在将实体和关系表示为稠密低维的向量。

## □ 知识图谱概述

- 知识图谱简介
- 知识表示学习
- 知识图谱应用

## □ 知识库问答系统

- 知识库问答简介
- 知识库问答方法
- 知识库问答与知识图谱

## □ 知识表示学习

### □ 目标：

通过将实体与关系投影到低维向量空间，得到实体与关系的语义信息表示。

### □ 方法：

首先在连续向量空间中表示实体和关系，并定义一个评分函数来评估事实三元组的合理性。然后通过最大化观察到的三元组的总合理性来得到实体和关系的嵌入表示。

## □ 语义匹配模型

- 利用基于相似度的评估方法
- 通过匹配实体和关系的潜在语义向量表示的相似度来衡量三元组的合理性

## □ 转移距离模型


- 利用基于距离的评估方法
- 通过计算两个实体之间进行关系转移后的距离来衡量三元组的合理性



## □ 代表方法：RESCAL及其扩展

### □ RESCAL, Nickel 2011


将知识图谱编码成一个三维张量，如图，如果三元组成立，则三阶张量对应元素值为1, 否则为0. 例第 $i$ 个实体和第 $j$ 个实体存在第 $k$ 种关系，对应位置 $(i, j, k)$ 元素值为1.



## □ 代表方法：RESCAL及其扩展

### □ RESCAL, Nickel 2011

由这个张量分解出一个核心张量和一个因子矩阵，核心张量中的每个二维矩阵切片代表一种关系，因子矩阵中的一行代表一个实体。由核心张量和因子矩阵还原的结果被视为三元组成立的概率。



## □ 代表方法：RESCAL及其扩展

### □ RESCAL, Nickel 2011

三元组(h, r, t)的得分定义如下，通过最小化重构误差学习实体和关系的表示。

$$f_r(h, t) = h^T M_r t$$

$h, t$ 为头尾实体向量

$M_r$ 为关系矩阵

优点：在编码过程中能综合整个知识库的信息

缺点：关系较多时，关系矩阵维度高，计算量大，对Freebase这类关系数目众多而又非常稀疏的大规模知识库效果不佳。

## □ 代表方法：RESCAL及其扩展

### □ DistMult, Yang 2015

DistMult模型通过简化关系矩阵来简化RESCAL模型，对每一个关系，要求其关系矩阵为一个简单的对角矩阵，以简化计算。实验结果表明这种简化极大降低了模型复杂度，同时模型效果得到提升。

$$f_r(h, t) = h^T M_r t$$

$$f_r(h, t) = h^T \text{diag}(r) t$$

$h, t$ 为头尾实体向量

$M_r$ 为关系矩阵

$\text{diag}(r)$ 为对角矩阵

# 方法：语义匹配模型

## □ 代表方法：RESCAL及其扩展

### □ Holographic Embeddings (HolE), Nickel 2016

Hole模型使用循环相关的运算将实体和关系表示在同一向量空间，成对交互压缩，既利用了RESCAL模型的表达能力，又拥有DisMult模型的效率和简单性。

$$f_r(h, t) = r^T (h \star t)$$

$$[h \star t]_i = \sum_{k=0}^{d-1} [h]_k \cdot [t]_{(k+i) \bmod d}$$

循环相关操作


# 方法：语义匹配模型

## □ 代表方法：RESCAL及其扩展

### □ Holographic Embeddings (HolE), Nickel 2016

对一个三元组(h, r, t),首先使用循环相关操作将头尾实体表示成 $h \star t$ , 再与关系匹配计算, 得到三元组的得分。

循环相关操作具有较强的表达能力, 具有不可交换性(即 $h \star t \neq t \star h$ ), 相关性和计算效率高等优点。



循环相关操作样例

## □ 代表方法：RESCAL及其扩展

### □ Complex Embeddings (ComplEx), Trouillon 2016

ComplEx通过引入基于复数的表示来扩展DistMult模型，以便更好地建模非对称关系。在ComplEx中，实体和关系的分布式表示不再依赖于实数空间，而是复数空间。

$$f_r(h, t) = \text{Re}(h^T \text{diag}(r) \bar{t})$$

$\bar{t}$ 表示 $t$ 的共轭， $\text{Re}(\cdot)$ 表示取复数值的实数部分。

Complex模型对非对称关系语义的捕捉以及预测效果具有较好效果。

## □ 代表方法：RESCAL及其扩展

### □ ANALOGY, Liu 2017

ANALOGY扩展了RESCAL方法，以进一步建模实体和关系的**类比属性**。要求关系的线性矩阵满足正态性和交换性。

$$f_r(h, t) = h^T M_r t$$

$$\text{正态性: } M_r M_r^T = M_r^T M_r$$

$$\text{交换性: } M_r M_{r'} = M_{r'} M_r$$




# 方法：语义匹配模型

## □ 代表方法：RESCAL及其扩展

### □ ANALOGY, Liu 2017

类比属性



“man is to king as woman is to queen, or a is to b as c is to d”

当实体具有相似属性时，假设a和b存在关系r，a和c存在关系r'，通过对称性，我们可以类推c和d存在关系r，b和d存在关系r'.

## □ 代表方法：神经网络匹配方法

### □ 语义匹配能量模型(Semantic Matching Energy), Bordes 2014

模型将实体和关系都用向量表示。SME使用多个矩阵运算捕获实体和关系之间的联系。首先对头节点 $h$ 和关系 $r$ 进行线性运算得到 $g_u(h, r)$ , 然后再对关系 $r$ 和尾节点 $t$ 做线性运算得到 $g_v(t, r)$ .

$$f_r(h, t) = g_u(h, r)^T g_v(t, r)$$


$$g_u(h, r) = M_u^1 h + M_u^2 r + b_u$$

$$g_v(t, r) = M_v^1 t + M_v^2 r + b_v$$

# 方法：语义匹配模型

## □ 代表方法：神经网络匹配方法

### □ 语义匹配能量模型(Semantic Matching Energy), Bordes 2014




# 方法：语义匹配模型

## □ 代表方法：神经网络匹配方法

### □ 张量神经网络模型(Neural Tensor Network), Socher 2013

NTN的基本思想是用双线性张量取代传统神经网络中的线性变换层，在不同维度下将头尾节点向量联系起来。

$$f_r(h, t) = r^T \tanh(h^T M_r^1 t + M_r^1 h + M_r^2 t + b_r)$$



## □ 代表方法：神经网络匹配方法

### □ 关联神经网络模型(Neural Association Model), Liu 2016


NAM模型首先将头实体向量和关系向量连接起来，然后输入到一个深度神经网络得到输出 $z$ 。最终得分由输出 $z$ 与尾节点变量计算得到。

$$\begin{aligned}f_r(h, t) &= t^T z^{(L)} \\z^{(l)} &= \text{ReLU}(M^{(l)} z^{(l-1)} + b^{(l)}) \\z^{(0)} &= [h; r]\end{aligned}$$

# 方法：语义匹配模型

## □ 代表方法：神经网络匹配方法

### □ 关联神经网络模型(Neural Association Model), Liu 2016



## □ 语义匹配模型

- 利用基于相似度的评估方法
- 通过匹配实体和关系的潜在语义向量表示的相似度来衡量三元组的合理性

## □ 转移距离模型

- 利用基于距离的评估方法
- 通过计算两个实体之间进行关系转移后的距离来衡量三元组的合理性

# 方法：转移距离模型

## □ 代表方法：TransE及其扩展

### □ TransE模型, Bordes 2013

受词向量空间中存在平移不变现象的启发，对每个三元组，TransE将关系向量作为头实体向量和尾实体向量之间的平移。


$$f_r(h, t) = -\|h + r - t\|_2^2$$

TransE模型简单有效，已经成为知识表示学习的代表模型，后续有大量关于对TransE模型的扩展改进。



# 方法：转移距离模型

- 代表方法：TransE及其扩展
  - TransE模型, Bordes 2013



# 方法：转移距离模型

## □ 代表方法：TransE及其扩展


### □ TransH模型, Wang 2014

为了解决TransE在处理复杂关系时的局限性，TransH提出让一个实体在不同关系下拥有不同的表示。它首先将头尾实体投影到关系所在超平面，然后在超平面计算头尾节点的平移。

$$h_{\perp} = h - w_r^T h w_r$$

$$t_{\perp} = t - w_r^T t w_r$$

$$f_r(h, t) = -\|h_{\perp} + r - t_{\perp}\|_2^2$$



# 方法：转移距离模型

## □ 代表方法：TransE及其扩展


### □ TransR模型, Lin 2015

TransR认为不同的关系有不同的语义空间。对每个关系定义一个矩阵，用于将实体向量转换到关系所属空间，然后在关系向量空间计算头尾节点的转移距离。

$$h_{\perp} = M_r h$$

$$t_{\perp} = M_r t$$

$$f_r(h, t) = -\|h_{\perp} + r - t_{\perp}\|_2^2$$



## □ 代表方法：TransE及其扩展

### □ TransD模型, Ji 2015

TransD模型是对TransR的一种改进，使用实体-关系对的两个投影向量的乘积来替换TransR中固定大小的转换矩阵。用向量运算代替矩阵运算，减少了计算量。

$$\begin{aligned}M_r^1 &= w_r w_h^T + I \\M_r^2 &= w_r w_r^T + I \\h_{\perp} &= M_r^1 h \\t_{\perp} &= M_r^2 t \\f_r(h, t) &= -\|h_{\perp} + r - t_{\perp}\|_2^2\end{aligned}$$

## □ 代表方法：TransE及其扩展

### □ TranSparse模型, Ji 2016

TranSparse模型提出使用稀疏矩阵代替TransR中的稠密矩阵。稀疏矩阵的稀疏度由关系连接的实体对数量决定。TranSparse有两个版本，一是头尾节点共享同一个投影矩阵，而是头尾节点分别使用两个不同的投影矩阵。

$$h_{\perp} = M_r(\theta_r)h$$

$$t_{\perp} = M_r(\theta_r)t$$

$$f_r(h, t) = -\|h_{\perp} + r - t_{\perp}\|_2^2$$

$M_r(\theta_r)$ 为稀疏映射矩阵。

# 方法：转移距离模型

## □ 代表方法：TransE及其扩展

### □ TransA模型, Xiao 2015

TransA模型为每一个关系引入了一个非负对称矩阵，并将损失函数中的距离度量改用马氏距离，为每一维学习不同的权重。

$$f_r(h, t) = -(|h + r - t|)^T M_r (|h + r - t|)$$

$M_r$ 为与关系相关的非负对称权值矩阵。

## □ 代表方法：TransE及其扩展

### □ KG2E模型, He 2015

KG2E模型在TransE的基础上提出一种基于分布的表示学习方法，使用基于高斯嵌入的方法在高维高斯分布空间中学习知识库中实体和关系的表示。将知识库中的实体、关系都约定为服从高斯分布。KG2E考虑两种计算概率相似度的方法：KL距离和期望距离。

$$h \sim \mathcal{N}(\mu_h, \Sigma_h)$$

$$t \sim \mathcal{N}(\mu_t, \Sigma_t)$$

$$r \sim \mathcal{N}(\mu_r, \Sigma_r)$$

## □ 整合额外的信息

- 前面的方法仅利用知识图谱的三元组结构信息进行学习，但仍存在大量的额外信息没有得到有效利用。
- 如实体类型、关系路径、文本描述、逻辑规则以及常识信息等。



## □ 整合额外的信息

### □ 实体类型(Entity Types):

(Guo, 2017)提出SSE模型，要求具有相同类型的实体在语义空间的距离接近。

### □ 关系路径(Relation Paths):

多步的关系路径也能反映实体之间的语义关系。(Lin,2015)提出path-based TransE, 采用相加等语义组合操作建立关系路径的向量表示。

## □ 整合额外的信息

### □ 文本描述(Textual Descriptions):

(Wang, 2014)等将给定的知识库与辅助文本语料库对齐，然后联合进行知识表示学习和词嵌入表示学习。

### □ 逻辑规则(Logical Rules):

(Wang, 2019)提出了一种逻辑规则增强方法，可以很容易的与其他基于转移距离的模型进行整合。

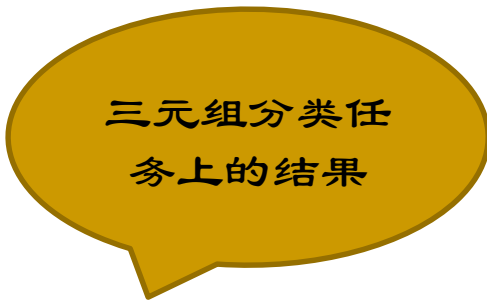
### □ 常识信息(Common-sense Concepts):

(Guan, 2018)提出Knowledge Graph Embedding with Concepts模型，将实体和实体的概念表示到语义空间。三元组的知识表示由概念图中的实体常识信息进行调整。

## □ 知识表示学习的方法

- 以TransE为代表的知识表示学习模型已经在知识图谱补全、关系抽取等任务中取得了瞩目的成果，但仍面临很多挑战，比如复杂关系建模、多源信息融合等。

Data sets	WN11	FB13
SME	70.0	63.7
NTN	70.4	87.1
TransE	75.9	81.5
TransH	78.8	83.3
TransR	85.9	82.5
TransD	86.4	89.1



三元组分类任务上的结果

## □ 知识表示学习的方法

Data sets	WN18		FB15K	
Metric	Mean Rank	Hits@10	Mean Rank	Hits@10
	Raw Filter	Raw Filter	Raw Filter	Raw Filter
RESCAL	1180 1163	37.2 52.8	828 683	28.4 44.1
SME	545 533	65.1 74.1	274 154	30.7 40.8
TransE	263 251	75.4 89.2	243 125	34.9 47.1
TransH	318 303	75.4 86.7	211 84	42.5 58.5
TransR	232 219	78.3 91.7	226 78	43.8 65.5
KG2E	362 348	80.5 93.2	183 69	47.5 71.5

链接预测的实验结果

## □ 知识图谱概述

- 知识图谱简介
- 知识表示学习
- 知识图谱应用

## □ 知识库问答系统

- 知识库问答简介
- 知识库问答方法
- 知识库问答与知识图谱

## □ 知识表示学习应用

### □ 主要有以下典型应用：

知识图谱补全

关系抽取、推荐系统、问答系统等

## □ 知识图谱补全

有以下子任务

### □ 链接预测

预测与一个给定实体具有特定关系的实体(Nickle 2016).也有预测两个实体之间的关系(Lin 2015, Nathani 2019).

### □ 实体分类

目标是将实体分类到不同的语义类别中，也就是得到实体的类型(Nickle 2012).

### □ 三元组分类

目标是验证一个三元组是否是一个正确的三元组，能否添加到知识库中(Lin 2015).

## □ 关系抽取

指从文本中抽取出已知实体间的关系。(Weston, 2013)提出将TransE与基于文本的提取器结合，得到了更好的关系提取效果。

## □ 推荐系统

指向用户推荐他们感兴趣的内容。(Zhang, 2016)提出一个混合推荐框架，利用知识图谱中异构信息来提高协同过滤的效果。

## □ 问答系统

基于知识库的自动问答系统。对于给定自然语言的问题，从知识库中检索出由三元组支持的答案。



## □ 知识图谱概述

- 知识图谱简介
- 知识表示学习
- 知识图谱应用

## □ 知识库问答系统

- 知识库问答简介
- 知识库问答方法
- 知识库问答与知识图谱

## □ 定义

- Knowledge base question answering, KBQA
- 即给定自然语言问题，通过对问题进行语义理解和解析，进而利用知识库进行查询、推理得出答案。
- 评价标准：召回率(Recall)，精确率(Precision), F1.
- 数据集：WebQuestions, SimpleQuestions, NLPCC KBQA数据集(中文)

## □ 知识图谱概述

- 知识图谱简介
- 知识表示学习
- 知识图谱应用

## □ 知识库问答系统

- 知识库问答简介
- 知识库问答方法
- 知识库问答与知识图谱

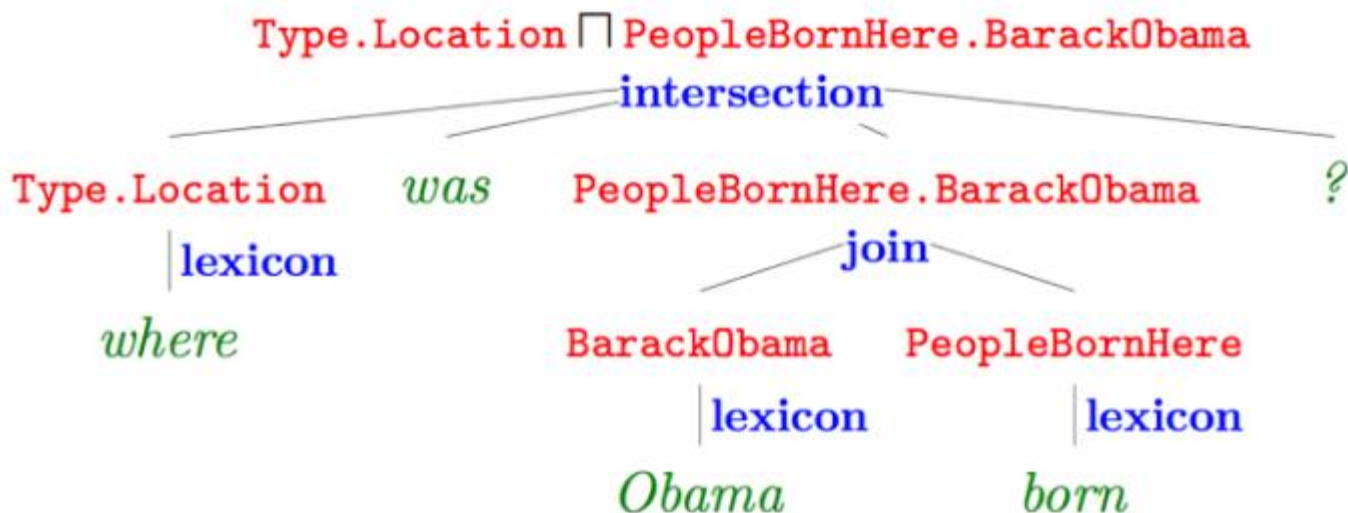
# 知识库问答方法

- 基于语义解析的方法

- 基于表示学习的方法

## □ 基于语义解析的方法

- 将自然语言转化成一系列形式化的逻辑形式，通过对逻辑形式进行自底向上的解析，得到问题的逻辑形式，通过对应的查询语句在知识库中查询得到答案。



(Berant, 2013)

## □ 基于语义解析的方法

### □ Berant, EMNLP 2013

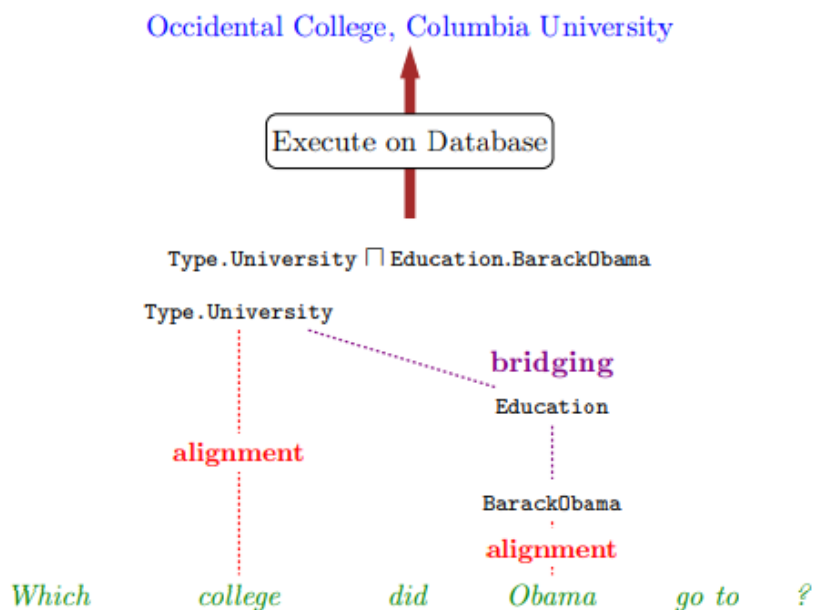
通过词汇映射和构建过程将自然语言转化为逻辑形式。

词汇映射通过构建词汇表完成，即自然语言与知识库实体或关系的单点映射，也称为对齐。构建词汇表有字符串匹配和基于统计的方法。

构建过程是对映射的节点进行连接、求交、聚合以及桥接操作，得到多个语法树，并通过训练一个分类器，对语法树进行筛选。

## □ 基于语义解析的方法

### □ Berant, EMNLP 2013




在WebQuestions上得到了31.4的F1-score

## □ 基于语义解析的方法

□ Yih, ACL 2015

为了更好的利用知识库，使用一种查询图的形式来代替语法解析树。



“Who first voiced Meg on Family Guy”对应的查询图



## □ 基于语义解析的方法


□ Yih, ACL 2015

步骤：

主题词链接

核心推导链

增加约束和聚合函数



以“Who first voiced Meg on Family Guy”为例

## □ 基于语义解析的方法

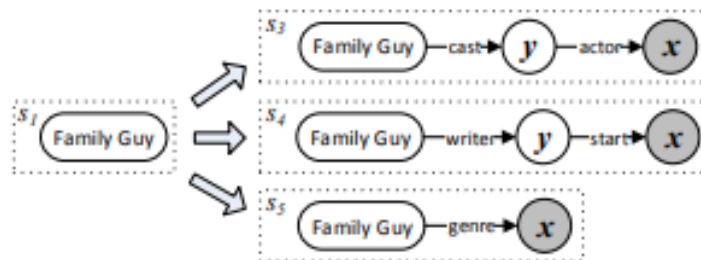
□ Yih, ACL 2015

步骤：

主题词链接

核心推导链

增加约束和聚合函数



以“Who first voiced Meg on Family Guy”为例

## □ 基于语义解析的方法

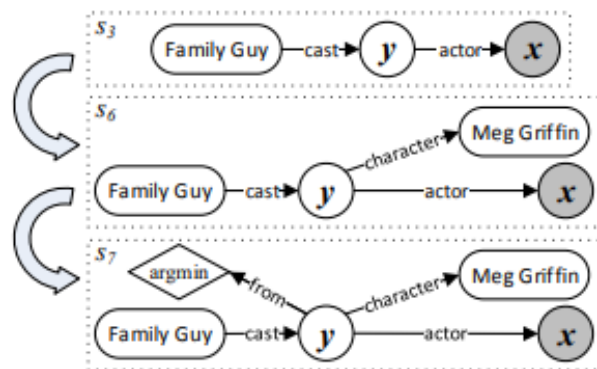
□ Yih, ACL 2015

步骤：

主题词链接

核心推导链

增加约束和聚合函数



以“Who first voiced Meg on Family Guy”为例

在WebQuestions上得到了52.5的F1-score

## □ 基于表示学习的方法

- 把知识库问答看做一个语义匹配过程。通过表示学习知识库以及用户问题的语义表示，得到低维空间的数值向量，再通过数值计算，直接匹配与用户问句语义最相似的答案。
- 随着深度学习的发展，基于表示学习的知识库问答取得了较好的效果。

## □ 基于表示学习的方法

### □ Bordes, 2015

将记忆网络用于KBQA. 整体思想是将知识库的知识存储道记忆模块, 问题经过输入模块转化成分布式表示, 输出模块选择与问题最相关的支撑记忆, 回答模块将对应的三元组的宾语作为最终答案输出。

在WebQuestions上得到了42.4的F1-score

在SimpleQuestions上得到了63.9的Accuracy

## □ 基于表示学习的方法

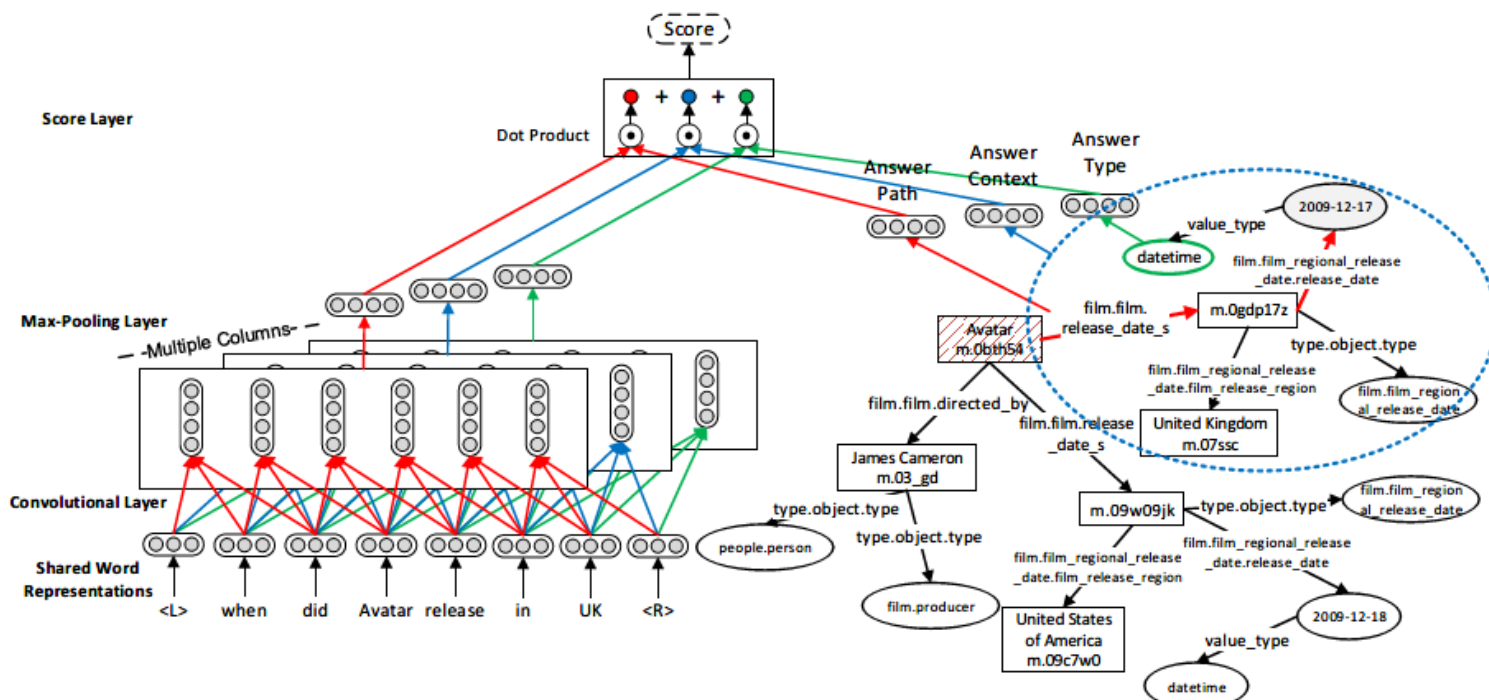
### □ Dong, ACL 2015

提出Multi-column CNN, 在答案端加入了更多信息, 答案类型、答案路径以及答案周围的实体和关系三种特征向量分别和问句向量做相似度计算, 最终的相似度为三种相似度之和。

$$S(q, a) = \underbrace{\mathbf{f}_1(q)^T \mathbf{g}_1(a)}_{\text{answer path}} + \underbrace{\mathbf{f}_2(q)^T \mathbf{g}_2(a)}_{\text{answer context}} + \underbrace{\mathbf{f}_3(q)^T \mathbf{g}_3(a)}_{\text{answer type}}$$

## 基于表示学习的方法

□ Dong, ACL 2015



在WebQuestions上得到了40.8的F1-score

Dong, ACL. Question answering over freebase with multi-column convolutional neural networks.

## □ 基于表示学习的方法

### □ Hao, ACL 2017

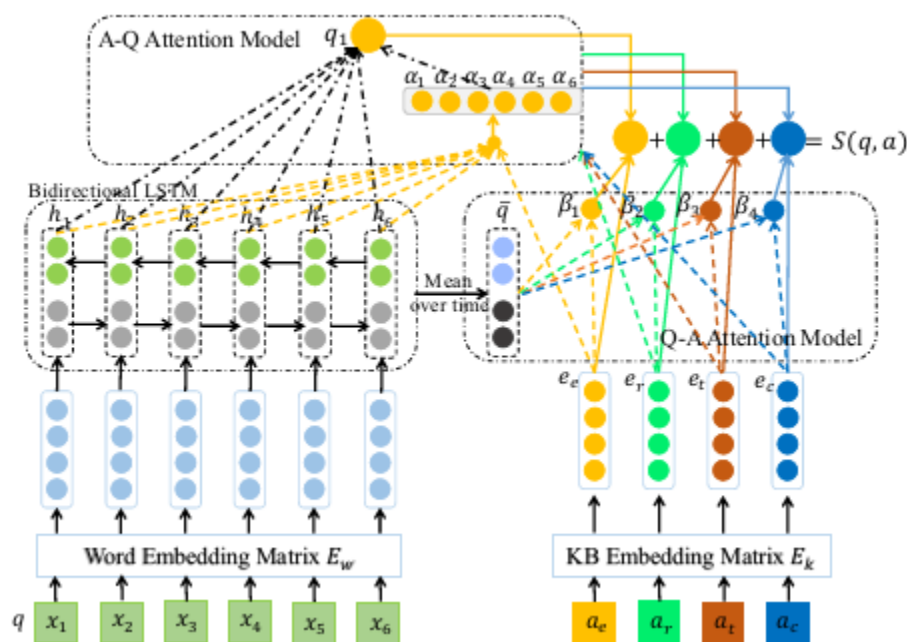
文章使用双向LSTM并结合问题引入注意力机制提取特征。主要思想是对于不同答案，关注问题的焦点也应该不同，根据候选答案的信息，引入注意力机制，对同一个问题提取不同的分布式表达。

同时，为了解决OOV问题，本文还利用TransE训练知识库，得到实体和关系对应的Embedding矩阵。



## □ 基于表示学习的方法

□ Hao, ACL 2017



在WebQuestions上得到了42.9的F1-score

Hao, ACL. An end-to-end model for question answering over knowledge base with cross-attention combining global knowledge.

## □ 基于表示学习的方法

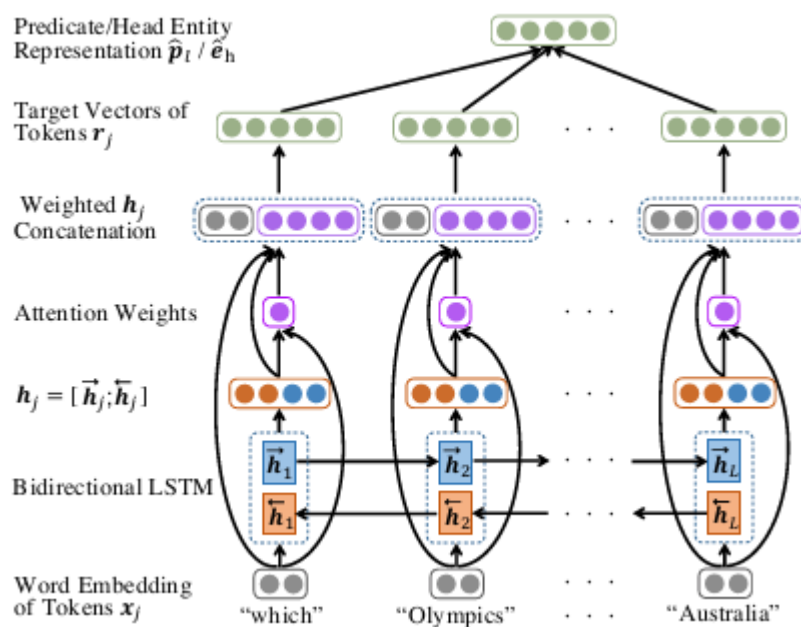
### □ Huang, WSDM 2019

提出KEQA模型, 不同于以往的直接计算问句和答案语义相似度的方法, 本文尝试通过关系和实体学习模型从问句分别重构出实体和关系的知识表示, 并进一步重构出三元组的知识表示, 最终答案为知识库中与重构三元组最接近的三元组。

同时文章也评估了不同的知识表示学习方法TransE, TransH, TransR对KEQA模型精度的影响。

## □ 基于表示学习的方法

### □ Huang, WSDM 2019



关系和主语表示学习模型

在SimpleQuestions上得到了75.4的Accuracy

## □ 基于表示学习的方法

### □ Huang, WSDM 2019

SimpleQuestions	
KEQA_noEmbed	0.731
KEQA_TransE	0.754 (+3.1%)
KEQA_TransH	0.749 (+2.5%)
KEQA_TransR	0.753 (+3.0%)

不同的知识表示学习方法对模型精度的影响

在SimpleQuestions上得到了75.4的Accuracy

## □ 基于表示学习的方法

### □ Xie, 2018

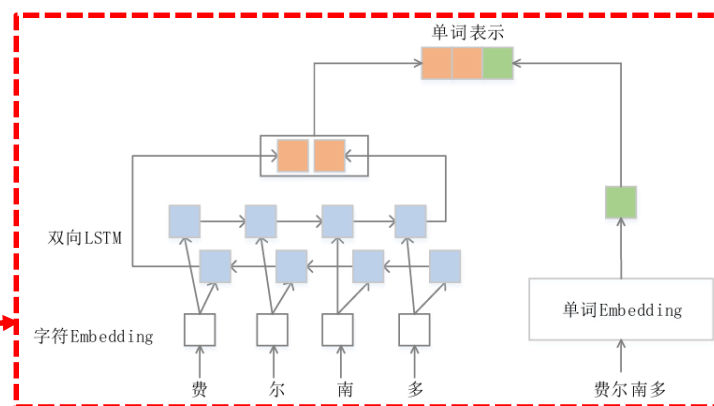

基于表示学习的方法主要有两个步骤，候选答案生成和答案选择。候选答案生成是指根据问题主题词检索知识库得到相关的候选三元组。传统方法采用问题的n元组检索得到候选集，存在很大的噪音，(Dai, 2016)将主题词提取视为序列标注问题。

答案选择是指根据问句与三元组的语义相似度，对候选答案排序。如何解决结构化的知识表示与自然语言问题之间的语义鸿沟仍然是一个具有挑战性的问题。

## 基于表示学习的方法

Xie, 2018

本文提出一种基于深度学习的主题实体抽取模型，结合了问句单词级别和字符级别的嵌入表示来学习问题的序列表示，并利用双向LSTM对单词序列编码，最后使用CNN网络根据单词的上下文信息预测单词是否为主题词。


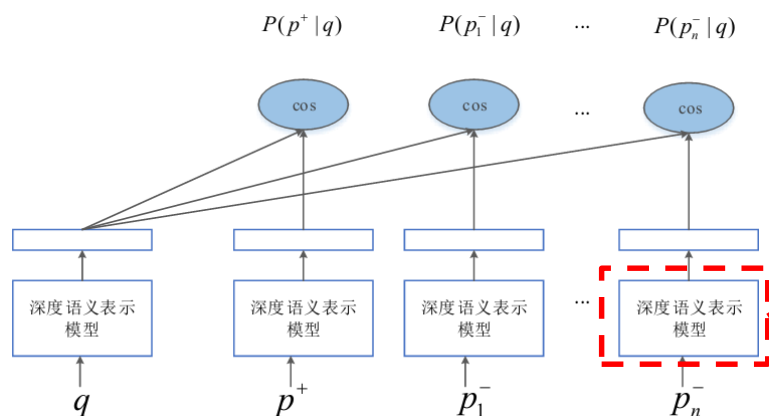


单词和字符级别的序列表示

## □ 基于表示学习的方法

□ Xie, 2018

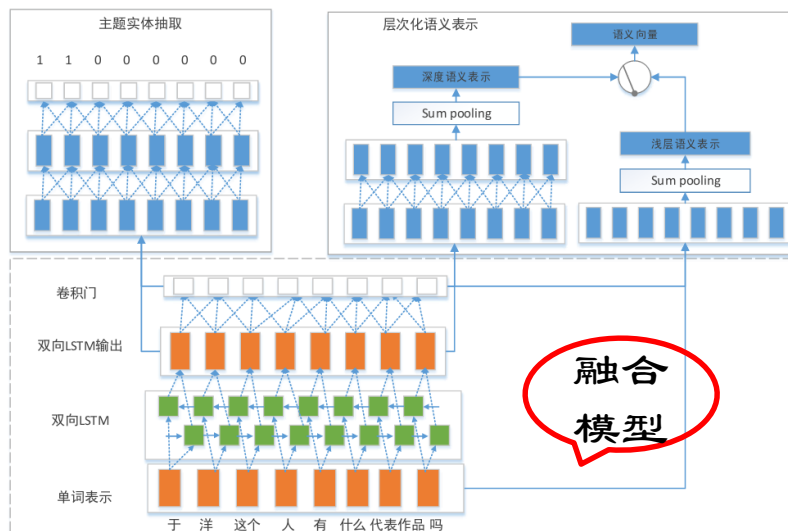
在答案选择部分，文章提出一种基于自注意力机制的深度语义表示模型。使用双向LSTM和CNN网络来构建深度语义模型，并提出一种基于局部和全局上下文的自注意力机制用于计算单词的注意力权重。



## 基于表示学习的方法

Xie, 2018

考虑语义表示学习和实体抽取任务之间的具有相互辅助作用，文章提出深度融合模型，将基于自注意力机制的深度语义表示模型与主题实体抽取模型结合，用多任务学习的方式进行联合训练。



在NLPCC-ICCPOL 2016数据集上得到了83.45的F1-score



- 基于语义解析的方法
- 基于表示学习的方法

Methods	F1
Berant, 2013	0.357
Dong, 2015	0.408
Bordes, 2015	0.422
Xu, 2016	0.471
Hao, 2017	0.429
Hu, 2018	0.496
Chen, 2019	0.518

WebQuestions实验结果

Methods	Accuracy
Bordes, 2015	0.639
Dai, 2016	0.626
Yin, 2016	0.683
Lukovnikov, 2017	0.712
Mohammed, 2018	0.732
Petrochuk, 2018	0.781
Huang, 2019	0.754

SimpleQuestions实验结果

## □ 知识图谱概述

- 知识图谱简介
- 知识表示学习
- 知识图谱应用

## □ 知识库问答系统

- 知识库问答简介
- 知识库问答方法
- 知识库问答与知识图谱

## □ 问题与挑战

### □ 复杂问句的深度学习知识库问答方法

现有方法大部分解决简单类型的问题，而对于含有歧义和限制条件的问题回答还有困难。

### □ 分布式表示与符号表示结合的知识库问答

基于深度学习的方法通过学习知识库和问题的语义表示来对问答进行建模，可以把语义解析的复杂过程变成简单的学习表示过程，但问答过程缺乏解释性，也容易受训练数据的质量和数量影响。

- Nickel, M., Tresp, V. and Kriegel, H.P., 2011, June. A Three-Way Model for Collective Learning on Multi-Relational Data. In ICML.
- Yang, B., Yih, S.W.T., He, X., Gao, J. and Deng, L., 2015. Embedding Entities and Relations for Learning and Inference in Knowledge Bases. In ICLR.
- Trouillon, T., Welbl, J., Riedel, S., Gaussier, É. and Bouchard, G., 2016, June. Complex embeddings for simple link prediction. In ICML.
- Nickel, M., Rosasco, L. and Poggio, T., 2016, March. Holographic embeddings of knowledge graphs. In AAAI.
- Liu, H., Wu, Y. and Yang, Y., 2017, August. Analogical inference for multi-relational embeddings. In ICML.
- Bordes, A., Glorot, X., Weston, J. and Bengio, Y., 2014. A semantic matching energy function for learning with multi-relational data. Machine Learning.
- Socher, R., Chen, D., Manning, C.D. and Ng, A., 2013. Reasoning with neural tensor networks for knowledge base completion. In NeurIPS.
- Liu, Q., Jiang, H., Evdokimov, A., Ling, Z.H., Zhu, X., Wei, S. and Hu, Y., 2016. Probabilistic reasoning via deep learning: Neural association models. arXiv.

- Bordes, A., Usunier, N., Garcia-Duran, A., Weston, J. and Yakhnenko, O., 2013. Translating embeddings for modeling multi-relational data. In NeurIPS.
- Wang, Z., Zhang, J., Feng, J. and Chen, Z., 2014, June. Knowledge graph embedding by translating on hyperplanes. In AAAI.
- Lin, Y., Liu, Z., Sun, M., Liu, Y. and Zhu, X., 2015, February. Learning entity and relation embeddings for knowledge graph completion. In AAAI.
- Ji, G., He, S., Xu, L., Liu, K. and Zhao, J., 2015. Knowledge graph embedding via dynamic mapping matrix. In ACL.
- Ji, G., Liu, K., He, S. and Zhao, J., 2016, February. Knowledge graph completion with adaptive sparse transfer matrix. In AAAI.
- Xiao, H., Huang, M., Hao, Y. and Zhu, X., 2015. TransA: An adaptive approach for knowledge graph embedding. arXiv.
- He, S., Liu, K., Ji, G. and Zhao, J., 2015, October. Learning to represent knowledge graphs with gaussian embedding. In CIKM.
- Berant, J., Chou, A., Frostig, R. and Liang, P., 2013. Semantic parsing on freebase from question-answer pairs. In EMNLP.

- Yih, W.T., Chang, M.W., He, X. and Gao, J., 2015. Semantic Parsing via Staged Query Graph Generation: Question Answering with Knowledge Base. In ACL.
- Dong, L., Wei, F., Zhou, M. and Xu, K., 2015. Question answering over freebase with multi-column convolutional neural networks. In ACL.
- Bordes, A., Usunier, N., Chopra, S. and Weston, J., 2015. Large-scale simple question answering with memory networks. arXiv.
- Xu, K., Reddy, S., Feng, Y., Huang, S. and Zhao, D., 2016. Question answering on freebase via relation extraction and textual evidence. arXiv.
- Dai, Z., Li, L. and Xu, W., 2016. Cfo: Conditional focused neural question answering with large-scale knowledge bases. In ACL.
- Yin, W., Yu, M., Xiang, B., Zhou, B. and Schütze, H., 2016. Simple question answering by attentive convolutional neural network. In COLING.
- Lukovnikov, D., Fischer, A., Lehmann, J. and Auer, S., 2017, April. Neural network-based question answering over knowledge graphs on word and character level. In WWW.

- Hao, Y., Zhang, Y., Liu, K., He, S., Liu, Z., Wu, H. and Zhao, J., 2017, July. An end-to-end model for question answering over knowledge base with cross-attention combining global knowledge. In ACL.
- Hu, S., Zou, L., Yu, J.X., Wang, H. and Zhao, D., 2018. Answering natural language questions by subgraph matching over knowledge graphs. TKDE.
- Mohammed, S., Shi, P. and Lin, J., 2018, June. Strong Baselines for Simple Question Answering over Knowledge Graphs with and without Neural Networks. In NAACL-HLT.
- Petrochuk, M. and Zettlemoyer, L., 2018. SimpleQuestions Nearly Solved: A New Upperbound and Baseline Approach. In EMNLP.
- Chen, Y., Wu, L. and Zaki, M.J., 2019. Bidirectional Attentive Memory Networks for Question Answering over Knowledge Bases. In NAACL-HLT.
- Huang, X., Zhang, J., Li, D. and Li, P., 2019, January. Knowledge graph embedding based question answering. In WSDM.

Thanks!

